TRACE — Comment TRACE réduit les hallucinations

Oct 21, 2026 · @Lamis

Le problème

TRACE part d'une idée simple : un modèle de langage ne doit être cru que lorsque le compte rendu et le guideline lui donnent raison. Tout ce qui suit découle de cette idée.

Le modèle (Mistral Small 4) lit les comptes rendus d'hospitalisation de patients septiques et en tire un graphe de connaissances : des **entités** (un diagnostic, un traitement, un biomarqueur…) et des **relations** entre elles (« ce traitement est administré au patient », « cette imagerie objective ce foyer »). Ce graphe doit pouvoir servir à des cliniciens. Or un modèle de langage produit parfois des éléments qui ne sont pas dans le document : ce sont les hallucinations.

Quelle hallucination TRACE combat. La littérature distingue deux familles (Ji et al., 2023 ; Huang et al., 2025) :

- l'hallucination de **factualité** : la sortie contredit la réalité du monde ;
- l'hallucination de **fidélité** : la sortie n'est pas soutenue par la source qu'on a donnée au modèle.

TRACE traite la seconde. La question n'est pas « est-ce médicalement vrai ? » mais « est-ce bien ce que dit *ce* compte rendu, sous la forme que demande *ce* guideline ? ».

Les cinq formes qu'elle prend dans un graphe clinique.

Forme	Ce qui se passe	Exemple
Entité inventée	Le modèle cite quelque chose qui n'est pas écrit, ou le reformule	un antibiotique jamais mentionné
Relation inventée	Deux entités réelles sont reliées par un lien que le texte n'établit pas	une imagerie reliée à un foyer qu'elle n'a pas montré
Mauvaise forme	L'information est juste mais mal rangée : deux informations fusionnées, une relation déguisée en entité, un lien qui ne respecte pas le guideline	« Augmentin 1 g x3/j » en une seule entité au lieu d'un traitement et de sa posologie

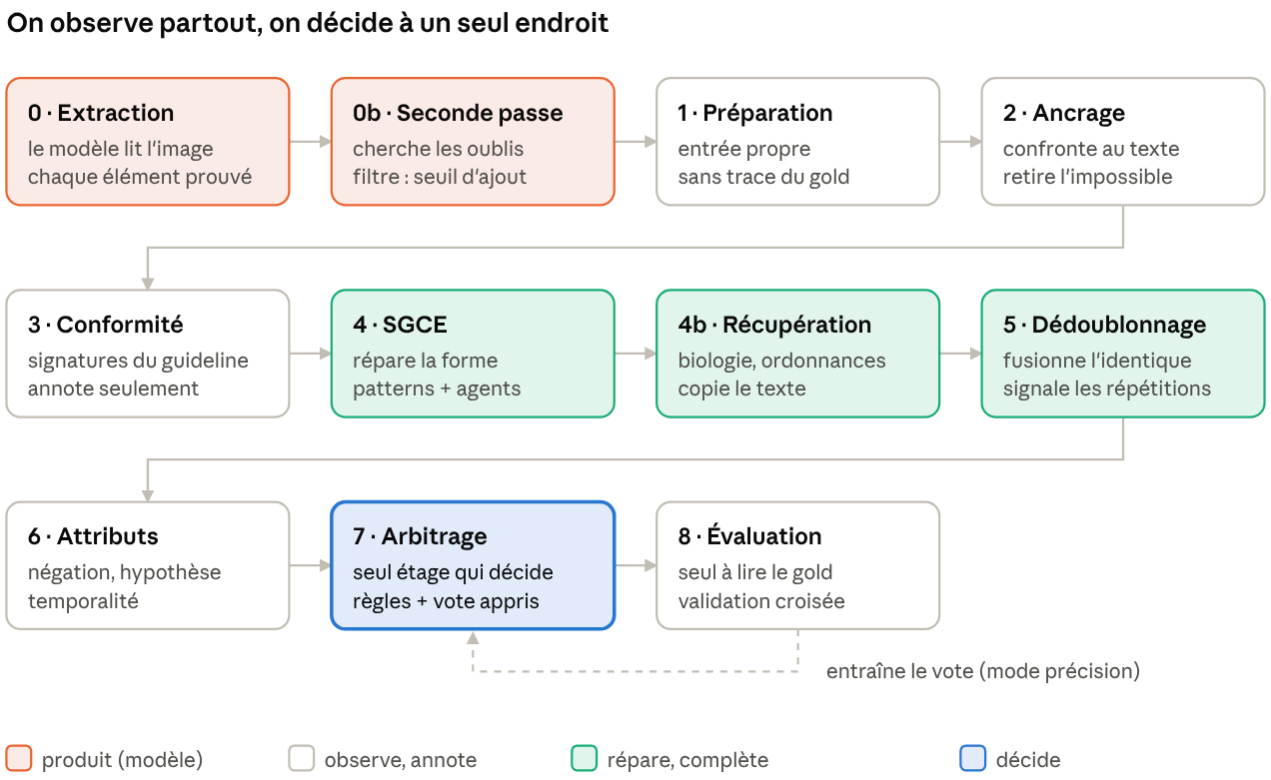
Forme	Ce qui se passe	Exemple
Contexte inversé	Un fait nié ou supposé est présenté comme affirmé	« pas de fièvre » devenu « fièvre »
Redondance	Le même fait apparaît plusieurs fois et gonfle le graphe	deux fois la même relation

Chaque étage de TRACE répond à une ou plusieurs de ces formes. Le schéma de la section suivante montre lesquelles et dans quel ordre.

Le fil conducteur

TRACE fait passer le graphe par six temps successifs. Chaque temps prend ce que le précédent lui transmet, répond à une seule question, et transmet au suivant un graphe enrichi de ses observations.

Temps	Question	Étages
1. Produire	Que contient le compte rendu, et qu'a-t-on oublié ?	0 Extraction, 0b Seconde passe
2. Préparer et vérifier	Est-ce écrit dans le texte ? Est-ce conforme au guideline ?	1 Préparation, 2 Ancrage, 3 Conformité au guideline
3. Réparer et compléter	L'information est-elle bien rangée, complète, sans double ?	4 SGCE, 4b Récupération, 5 Dédoublonnage
4. Qualifier	Le fait est-il présent, nié, supposé, passé ?	6 Attributs
5. Décider	Faut-il garder cet élément, et avec quelle confiance ?	7 Arbitrage
6. Évaluer	TRACE fait-il vraiment mieux, et où ?	8 Évaluation



le parcours d'un compte rendu dans TRACE

On lit le schéma ligne par ligne, de gauche à droite. La flèche en pointillés indique que l'évaluation entraîne le vote utilisé par l'arbitrage en mode précision, toujours sur des documents que ce vote n'a pas vus.

Les quatre règles qui relient les étages.

1. **Deux références seulement.** Le texte du compte rendu dit ce qui est vrai pour ce patient ; le guideline dit sous quelle forme l'écrire. Rien d'autre ne sert à juger.
2. **Observer partout, décider à un seul endroit.** Les étages ne retirent que l'impossible ; ils notent le douteux. La décision est prise à l'arbitrage, avec toutes les observations réunies, et chaque retrait y reçoit une règle nommée.
3. **Rien n'est inventé par TRACE.** Tout ce que TRACE ajoute ou répare est recopié du texte. Un cas ambigu n'est pas corrigé.
4. **Le gold n'est lu qu'à la fin.** Aucune règle n'est réglée en regardant les réponses ; ce qui est appris est mesuré sur des documents jamais vus.

Un exemple suivi de bout en bout

Pour rendre le parcours concret, on suit un extrait de compte rendu (construit pour l'explication) et ce que devient chaque élément proposé par le modèle.

> **Antécédents** — HTA. Diabète de type 2.
>
> **Histoire de la maladie** — Suspicion de pyélonéphrite. Pas de fièvre à l'entrée.
>
> **Biologie** — Leucocytes 18.2 4.0-10.0 G/L
>
> **Conclusion** — Choc septique sur pneumopathie. Scanner thoracique : foyer lobaire inférieur droit.
>
> **Traitement de sortie** — Augmentin 1g x3/j

Élément proposé par le modèle	Problème	Ce que fait TRACE	Où
Entité « antibiothérapie adaptée »	N'est écrite nulle part	Retirée, avec ses relations	Ancrage dans le texte
Relation « HTA → facteur de risque de → choc septique »	Les deux termes sont écrits dans des parties éloignées ; le texte ne les relie pas	Retirée si les deux termes ne se rencontrent jamais à proximité ; sinon gardée avec une confiance abaissée	Ancrage, puis décision
Entité « Augmentin 1g x3/j » typée TRAITEMENT	Deux informations fusionnées	Séparée en un TRAITEMENT et une POSOLOGIE, reliés entre eux	Réparation de la forme (SGCE)
La ligne « Leucocytes … », oubliée par le modèle	Oubli	Ajoutée comme BIOMARQUEUR, recopiée de la ligne	Récupération structurée
La relation « Scanner thoracique → objective → foyer lobaire inférieur droit » proposée deux fois	Redondance	Une seule copie gardée	Dédoublonnage
Entité « fièvre »	Le texte dit « pas de fièvre »	Marquée niée, puis retirée	Qualification, puis décision
Entité « pyélonéphrite »	Le texte dit « suspicion de »	Marquée hypothétique ; gardée, mais signalée comme moins sûre	Qualification, puis décision

Élément proposé par le modèle	Problème	Ce que fait TRACE	Où
Relation « Scanner thoracique → objective → foyer » (la copie gardée)	Aucun	Gardée avec la confiance la plus haute : preuve dans le texte, termes sur la même ligne, conforme au guideline	Décision

On retrouve dans ce tableau les cinq formes d'hallucination, chacune traitée à un endroit précis du parcours. Les sections suivantes expliquent chaque endroit dans l'ordre.

Temps 1 — Produire les candidats

Ce premier temps ne réduit pas encore les hallucinations. Il produit la matière première, mais il la produit d'une façon qui la rend **vérifiable** : c'est ce qui permet tout le reste.

Étage 0 — Extraction par le modèle

La question à laquelle il répond. Quelles entités et quelles relations le compte rendu contient-il ?

Comment ça se passe.

1. Chaque page est donnée au modèle sous forme d'image. Le modèle la lit directement, sans passer par un logiciel d'OCR séparé : il voit la mise en page (tableaux de biologie, titres de section), ce qu'un texte brut perdrait (Kim et al., 2022 ; Xu et al., 2020).
2. Le modèle extrait d'abord les **entités** de la page, avec les types définis par le guideline.
3. Il extrait ensuite les **relations** entre ces entités, en choisissant seulement parmi les relations que le guideline autorise.
4. Pour chaque élément, il doit fournir trois choses en plus : la **preuve** (le passage exact du texte qui le justifie), s'il est **nié** ou **hypothétique**, et son propre **niveau de confiance**.
5. Le modèle travaille en mode déterministe : le même document donne toujours la même extraction.

Pourquoi exiger une preuve. Une affirmation accompagnée de sa source peut être contrôlée. C'est l'idée de FActScore (Min et al., 2023) : découper la sortie en affirmations élémentaires et vérifier chacune contre la source. TRACE l'applique à chaque entité et à chaque relation.

Pourquoi demander une confiance au modèle. Les modèles de langage savent en partie quand ils se trompent (Kadavath et al., 2022). Ce doute déclaré sera réutilisé au moment de décider.

Ce qu'il transmet. Un graphe brut, où chaque élément porte sa preuve, sa négation, son hypothèse et sa confiance.

Étage 0b — Seconde passe

La question à laquelle il répond. Qu'est-ce que le modèle a oublié ?

Pourquoi cet étage existe. Un post-traitement peut retirer ou corriger, mais il ne peut pas deviner ce que le modèle n'a jamais extrait. Pour gagner en rappel, il faut redemander au modèle.

Comment ça se passe.

1. On redonne au modèle la page **et** la liste de ce qu'il a déjà extrait. On lui demande seulement ce qui manque : d'abord les entités, puis les relations.
2. Chaque demande est posée plusieurs fois. Un élément n'est retenu que s'il revient dans la majorité des réponses. Une réponse stable d'un essai à l'autre est plus souvent juste qu'une réponse isolée (Wang et al., 2023 ; Manakul et al., 2023).
3. Une entité ajoutée doit avoir sa preuve recopiée telle quelle de la page. Une relation ajoutée doit respecter le guideline et relier deux entités existantes.
4. Un **filtre** trie ensuite les ajouts.

Le filtre, et pourquoi il garde des entités mais aucune relation ajoutée. Un ajout n'est utile que s'il est juste assez souvent ; sinon, il apporte plus d'erreurs que de réponses justes et le résultat global se dégrade. Cette règle du seuil d'ajout est expliquée en détail au temps 6.

- Pour les **entités**, certains types (micro-organismes, traitements, biomarqueurs, évolution) sont assez souvent justes quand ils reviennent dans toutes les réponses du modèle et ne sont pas niés. Ils sont gardés. Une entité proposée indépendamment par deux passes différentes est aussi plus souvent juste, et elle est gardée pour certains types.
- Pour les **relations**, aucun groupe n'atteint le seuil, quel que soit le critère regardé : type de relation, nombre de votes, distance entre les termes, ancrage dans le texte. Les relations ajoutées relient presque toujours deux entités réelles par un lien plausible que le texte n'écrit pas (une coloscopie reliée à une sinusite, une HTA présentée comme cause d'un choc septique). Les ajouter fait baisser la qualité du graphe sur chaque moitié du corpus. Elles sont donc toutes écartées.

Ce qu'il faut bien comprendre. Les relations de l'extraction initiale sont **toutes conservées** et passent dans la suite de TRACE. Seules les relations **ajoutées par la seconde passe** sont écartées. Ce n'est pas un choix fait d'avance : c'est le résultat d'une mesure, obtenu avec la même règle que celle qui a fait garder certaines entités.

Lien avec la littérature. Demander à un modèle de compléter sa propre sortie, sans information extérieure, apporte peu (Kamoi et al., 2024 ; Huang J. et al., 2024). Le résultat sur les relations confirme ce constat ; le gain sur les entités vient des filtres qui ajoutent un contrôle extérieur (la preuve recopiée, l'accord entre plusieurs réponses).

Ce qu'il transmet. Le graphe initial, enrichi des seules entités ajoutées qui ont passé le filtre.

Temps 2 — Préparer et vérifier

Ce deuxième temps confronte le graphe à ses deux références : le **texte du compte rendu** (ce qui est écrit) et le **guideline** (la forme attendue). Sa règle de conduite : mesurer beaucoup, retirer très peu. On ne retire ici que ce qui est impossible ; tout ce qui est seulement douteux est noté et laissé au temps de la décision.

Étage 1 — Préparation

La question à laquelle il répond. L'entrée est-elle propre et honnête ?

Comment ça se passe.

1. Il retire toute relation qui aurait été ajoutée ou validée, dans une version antérieure du travail, en regardant l'annotation de référence. Sans ce retrait, l'évaluation mesurerait l'annotation elle-même et non TRACE.
2. Il uniformise l'écriture des noms d'entités (certains caractères, comme le symbole « micro », existent sous deux formes qui se ressemblent). Les mentions telles qu'elles apparaissent dans chaque page restent, elles, identiques au texte, car elles seront comparées mot pour mot au texte plus tard.
3. Il donne un identifiant à chaque relation qui n'en a pas, pour que chaque étage puisse la suivre et la retirer sans ambiguïté.

Ce qu'il transmet. Un graphe propre, sans aucune trace de l'annotation de référence.

Étage 2 — Ancrage dans le texte

La question à laquelle il répond. Ce que dit le graphe est-il écrit dans le compte rendu ?

Comment on décide qu'un terme « est dans le texte ». Le texte et le terme sont mis sous une forme comparable (minuscules, sans accents, sans ponctuation). Le terme est reconnu s'il apparaît tel quel, ou si la plupart de ses mots porteurs de sens sont présents,

en tolérant les accords et les pluriels. Une exigence s'ajoute : **tous les nombres** du terme doivent être dans le texte. Un libellé juste avec une valeur inventée reste une hallucination grave.

Ce qu'il observe pour chaque relation.

- **La preuve** : la citation donnée par le modèle existe-t-elle vraiment dans le texte ?
- **La distance** : les deux termes reliés apparaissent-ils sur la même ligne, dans le même paragraphe, ou jamais près l'un de l'autre ?
- **La section** : dans quelle partie du compte rendu la relation est-elle citée (antécédents, examen, biologie, évolution, conclusion…) ?

Pour chaque entité, il note si elle figure dans le document, et si elle figure **mot pour mot dans sa propre page**.

Ce qu'il retire : seulement l'impossible.

- une entité absente de tout le document (elle a été inventée), avec les relations qui en dépendent ;
- une relation dont une extrémité n'existe pas dans le texte ;
- une relation dont la citation de preuve n'existe pas dans le texte ;
- une relation dont les deux termes ne se rencontrent jamais à proximité l'un de l'autre : le texte ne peut pas les relier.

Pourquoi ne pas retirer davantage ici. Une relation dont les termes sont dans le même paragraphe mais pas sur la même ligne peut être juste ou fausse. La juger ici, avec une seule information, serait trancher trop tôt. Elle est notée et sera jugée au temps de la décision, avec tous les autres signaux.

Dans l'exemple. « Antibiothérapie adaptée » n'est écrite nulle part : elle est retirée ici. « HTA → facteur de risque de → choc septique » relie deux termes écrits dans des parties éloignées : si ces termes ne se rencontrent jamais à proximité, la relation est retirée ici.

Lien avec la littérature. C'est l'application directe de la définition de l'hallucination de fidélité : un contenu non soutenu par la source (Ji et al., 2023 ; Huang et al., 2025).

Étage 3 — Conformité au guideline

Cet étage s'appelait auparavant « validation ontologique ». Le nouveau nom décrit mieux ce qu'il fait : l'étage ne raisonne pas sur une ontologie au sens formel ; il compare chaque relation aux signatures définies dans le guideline TRACE-Sepsis.

La question à laquelle il répond. Chaque relation a-t-elle la forme que le guideline autorise ?

Ce qu'est une signature. Le guideline définit, pour chaque relation, le type d'entité attendu au départ et le type attendu à l'arrivée. Par exemple, « imagerie objective un foyer » part d'une IMAGERIE_PROCEDURE et arrive à un FOYER_INFECTIEUX.

Comment ça se passe. Pour chaque relation, l'étage pose trois questions et donne un statut :

1. La relation existe-t-elle dans le guideline ? Sinon : relation inconnue.
2. L'entité de départ a-t-elle le type attendu ? Sinon : départ non conforme.
3. L'entité d'arrivée a-t-elle le type attendu ? Sinon : arrivée non conforme.

Une relation qui passe les trois questions est **conforme**.

Pourquoi il ne retire rien. Deux raisons. D'abord, l'étage suivant peut réparer une relation non conforme (en la rattachant à la bonne entité ou en corrigeant un type). Ensuite, quand une relation est non conforme, c'est le plus souvent le **type d'une entité** qui est faux, alors que le lien lui-même est juste. Retirer la relation ferait perdre une information correcte. La non-conformité sera donc un signal de doute au moment de décider, pas un motif de retrait.

Lien avec la littérature. Déclarer séparément les contraintes de forme et les vérifier sur les données est le principe des langages de contraintes comme SHACL (Knublauch et Kontokostas, 2017). S'appuyer sur un référentiel clinique pour limiter les hallucinations est aussi la démarche d'Ali, Taha et Morsey (2026).

Ce que transmet le temps 2. Un graphe d'où l'impossible a disparu, et où chaque élément porte ses observations : preuve, distance, section, présence mot pour mot, conformité au guideline.

Temps 3 — Réparer et compléter

Le temps 2 a enlevé l'impossible et noté le douteux. Il reste des erreurs d'un autre genre : l'information est dans le texte, mais elle est **mal rangée** dans le graphe, ou elle a été oubliée, ou elle est en double. Ce troisième temps ne juge pas : il remet le graphe en forme, toujours à partir du texte.

Étage 4 — SGCE : réparer la forme du graphe

La question à laquelle il répond. Le graphe a-t-il la bonne forme, celle que le guideline décrit ?

Ce qu'il cherche. Des **motifs d'erreur** connus, appelés *patterns*. Chacun décrit une façon typique dont un modèle range mal une information juste.

Famille	L'erreur de forme	Exemple	La réparation
A	Deux informations fusionnées dans une seule entité, ou un lien attendu qui manque	« Augmentin 1g x3/j » en une seule entité traitement	Séparer en deux entités et les relier
B	Une entité manque : une relation pointe vers une entité inexistante, ou une chaîne de deux relations a été raccourcie en une	une relation qui vise un identifiant absent	Rattacher à l'entité existante, ou créer l'entité si le texte la donne explicitement
C	Une relation a été extraite comme une entité	une « entité » qui décrit en réalité un lien entre deux choses	Remplacer cette entité par la relation correspondante
D	Une relation dont le départ ou l'arrivée n'a pas le type attendu par le guideline	un traitement relié là où le guideline attend un diagnostic	Rattacher autrement, corriger un type, ou retirer le lien invalide

Deux étapes complètent ces familles : la **réparation de relations** (remplacer une relation par celle qui correspond exactement aux types observés, quand il n'y en a qu'une) et la **résolution des relations orphelines** (rattacher une relation qui a perdu une extrémité à l'unique entité compatible, ou la retirer s'il n'y en a aucune).

Comment ça se passe, pour chaque pattern. Toujours les quatre mêmes temps :

1. **Détecter** : lister les cas candidats, sans rien modifier.
2. **Valider** : ne garder que les cas où une seule correction est possible et où le texte la soutient ; les autres sont classés ambigus.
3. **Corriger** : appliquer seulement les corrections validées.
4. **Contrôler** : vérifier que la correction n'a rien cassé.

Un cas ambigu n'est **jamais** corrigé à ce stade.

Le multi-agent : un second avis pour les cas ambigus. « Le symbolique tranche d'abord » : les agents ne voient que les cas que les patterns ont détectés sans pouvoir choisir une correction sûre.

1. Des agents spécialisés, un par famille, proposent une action en regardant le graphe et le texte.

2. Les cas encore indécis passent devant un arbitre, qui fait voter trois points de vue indépendants : **le texte** soutient-il l'action ? **le guideline** est-il respecté après l'action ? **la cohérence clinique** locale est-elle préservée ?
3. L'action est appliquée si les trois sont d'accord, ou si deux sont d'accord sans opposition ferme du troisième et avec une preuve explicite dans le texte. Sinon, on **s'abstient** : rien n'est changé.

Ces agents ne sont pas des modèles de langage : ce sont des règles explicites. C'est un choix voulu. Faire débattre plusieurs modèles de langage (Du et al., 2024) risque de faire valider une erreur que tous partagent ; des agents à règles donnent des décisions reproductibles et explicables.

D'où vient l'idée. SGCE réunit quatre courants de la littérature :

- le **raffinement de graphes** après leur construction, pour détecter et corriger les erreurs (Paulheim, 2017) ;
- la **réparation de données sous contraintes**, qui corrige les violations en tenant compte de leur contexte plutôt qu'une par une (Chu, Ilyas et Papotti, 2013 ; Rekatsinas et al., 2017 ; Fan, Wu et Xu, 2016) ;
- les **patrons de modélisation**, en particulier la représentation d'un lien par un nœud, à l'origine de la famille C (Gangemi, 2005 ; Noy et Rector, 2006) ;
- l'**abstention** quand le risque d'erreur est trop élevé (Chow, 1970 ; Geifman et El-Yaniv, 2017).

L'apport de SGCE est d'assembler ces idées pour les erreurs de forme d'un graphe clinique produit par un modèle de langage, avec le guideline comme référence.

Ce qu'il transmet. Un graphe remis en forme. Chaque relation créée par SGCE est marquée comme telle, pour être contrôlée au temps de la décision.

Étage 4b — Récupération structurée

La question à laquelle il répond. Le modèle a-t-il oublié des éléments faciles à retrouver sans lui ?

Pourquoi c'est possible sans modèle. Certaines parties d'un compte rendu ont une forme fixe. Une ligne de biologie s'écrit toujours « libellé, valeur, normes, unité » ; une ligne d'ordonnance s'écrit « médicament, puis posologie ». Une règle simple suffit à les lire.

Comment ça se passe.

1. Dans la biologie, chaque ligne de cette forme que le modèle n'a pas extraite devient un biomarqueur.
2. Dans les traitements habituels et la prescription de sortie, chaque ligne devient un traitement et sa posologie.

3. Sur une même ligne d'ordonnance, le traitement est relié à sa posologie.

Les garde-fous. Rien n'est inventé : chaque ajout est un morceau de ligne recopié du texte. On n'ajoute rien qu'une entité existante couvre déjà. Les lignes qui ressemblent à de la biologie mais n'en sont pas (valeurs témoins du laboratoire, réglages du ventilateur) sont ignorées. Une règle qui aurait relié chaque traitement au patient a été testée puis abandonnée, parce qu'elle dégradait le résultat.

Lien avec la littérature. C'est l'approche des systèmes cliniques à règles pour les parties semi-structurées des documents (Savova et al., 2010 ; Fraile Navarro et al., 2023).

Dans l'exemple. La ligne « Leucocytes … », oubliée par le modèle, est ajoutée comme biomarqueur.

Étage 5 — Dédoublonnage

La question à laquelle il répond. Le graphe dit-il la même chose plusieurs fois ?

Comment ça se passe.

1. Deux entités strictement identiques (même type, même nom, même page, même preuve, même valeur…) sont fusionnées ; leurs relations sont reportées sur l'entité gardée.
2. Deux relations strictement identiques (mêmes entités, même type) : une seule est gardée.
3. Une relation qui répète un fait déjà présent sous d'autres identifiants est seulement **signalée**, pas retirée.

Pourquoi ne pas retirer les répétitions. Un compte rendu peut citer deux fois le même fait, à l'entrée et à la sortie par exemple. La répétition devient un signal de doute pour le temps de la décision.

Ce que transmet le temps 3. Un graphe remis en forme, complété et sans copie, dont chaque élément garde ses observations.

Temps 4 — Qualifier le contexte

Étage 6 — Attributs cliniques

La question à laquelle il répond. Ce terme décrit-il un fait **présent**, **nié**, **supposé**, ou **passé** ?

Pourquoi c'est indispensable. Dans un compte rendu, la présence d'un mot ne veut pas dire que le patient a ce qu'il désigne. « Pas de fièvre » contient le mot fièvre ; « suspicion de pyélonéphrite » ne pose pas le diagnostic ; un antécédent ne décrit pas le séjour actuel.

Un graphe qui ignore ce contexte affirme des choses que le texte n'affirme pas : c'est une hallucination par inversion.

Comment ça se passe. Pour chaque entité, l'étage regarde le texte juste avant la mention et la partie du compte rendu où elle se trouve.

Attribut	Comment il est déterminé
Négation	Un déclencheur de négation (« pas de », « absence de », « aucun », « sans », « éliminé », « non retrouvé »…) se trouve **juste avant** la mention ; ou le modèle lui-même l'a marquée niée
Hypothèse	Même mécanisme avec des déclencheurs d'incertitude (« suspicion de », « probable », « évoqué », « à éliminer », « à discuter »…)
Temporalité	D'après la section : antérieur (antécédents, traitements habituels), sortie (prescription de sortie), ou séjour
Unité	Pour une valeur chiffrée sans unité, l'unité écrite dans le nom est renseignée

Pourquoi le déclencheur doit toucher la mention. Le mot de négation doit être le dernier avant la mention. Dans « pas de fièvre, CRP élevée », la fièvre est niée mais pas la CRP. Une fenêtre trop large nierait à tort tout ce qui suit.

Pourquoi il ne retire rien. Comme les étages de vérification, il observe et note. La décision revient au temps suivant, où la négation retire une entité et où l'hypothèse devient un signal de doute.

Lien avec la littérature. La détection de la négation par déclencheurs proches de la mention vient de NegEx (Chapman et al., 2001) ; l'ajout de l'hypothèse et de la temporalité vient de ConText (Harkema et al., 2009). Ces algorithmes qualifient des mentions mais n'agissent pas sur un graphe. TRACE va plus loin : les attributs servent directement à décider du sort des **entités et des relations**.

Dans l'exemple. « Fièvre » est marquée niée ; « pyélonéphrite » est marquée hypothétique ; « HTA » et « diabète de type 2 » sont marqués antérieurs.

Ce qu'il transmet. Un graphe complet où chaque élément porte toutes ses observations : celles du texte, du guideline, de la réparation, de la redondance et du contexte. Tout est prêt pour décider.

Temps 5 — Décider

Étage 7 — Arbitrage

La question à laquelle il répond. Pour chaque entité et chaque relation : faut-il la garder, et avec quel degré de confiance ?

Pourquoi un seul étage décide. Tous les étages précédents ont observé sans juger, sauf pour l'impossible. Toutes leurs observations se rejoignent ici. Ainsi, chaque retrait a **une seule règle** pour cause, écrite à côté de l'élément, et chaque décision peut être expliquée au médecin.

Les agents. Cinq lecteurs, chacun spécialisé dans un type d'observation. Ce sont des règles, pas des modèles de langage.

Agent	Ce qu'il apporte	Observé au
Ancrage	La preuve existe-t-elle ? Les termes sont-ils proches ? Dans quelle section ?	Temps 2
Conformité au guideline	La relation respecte-t-elle sa signature ? (recalculé, car la réparation a pu changer les liens)	Temps 2
Redondance	Le fait est-il répété ?	Temps 3
Contexte	Le terme est-il nié, supposé, antérieur ?	Temps 4
Provenance	L'élément vient-il de l'extraction directe, d'une déduction, d'une réparation ?	Temps 1 et 3

Le mode standard : des règles fixées à l'avance

Les entités sont traitées d'abord, les relations ensuite.

Règle	S'applique à	Retire quand…	Pourquoi
E1	Entité	elle ne figure pas **mot pour mot** dans le texte de sa page	Le modèle a reformulé ou inventé : la mention n'est plus fidèle à la source
E2	Entité	elle est **niée** dans le texte	Un fait absent n'est pas une entité clinique présente

Règle	S'applique à	Retire quand…	Pourquoi
E3	Entité	le modèle lui-même a déclaré une confiance **moyenne ou faible**	On respecte le doute que le modèle a exprimé (Kadavath et al., 2022)
R2	Relation	l'entité qu'elle affirme a été marquée niée par le modèle	L'extraction se contredit elle-même
R3	Relation	elle a été créée pendant la réparation et échoue au contrôle d'ancrage	Une réparation doit passer le même contrôle que l'extraction

Pourquoi la non-conformité au guideline ne retire pas. Comme expliqué au temps 2, le lien est en général juste et c'est le type d'une entité qui est faux. La non-conformité baisse donc la confiance mais ne retire pas.

La cascade. Quand une entité est retirée, les relations qui la touchent n'ont plus de sens : elles sont retirées avec elle. Deux précisions :

- une relation n'est retirée que si l'entité a disparu de **toutes** les pages ; si elle existe encore sur une autre page, la relation reste ;
- la cascade va dans un seul sens : retirer une relation ne retire jamais une entité, car une entité peut être juste sans être reliée.

Le niveau de confiance des relations gardées. Une relation qui n'a déclenché aucune règle de retrait peut tout de même présenter des **signaux faibles**, qui ne suffisent pas seuls à la retirer :

- sa preuve n'est pas citée ;
- ses deux termes sont éloignés dans le texte ;
- elle a été déduite et non extraite directement ;
- elle répète un fait déjà présent ;
- l'entité qu'elle affirme est précédée d'une négation ;
- cette entité est précédée d'une hypothèse ;
- elle n'est pas conforme au guideline.

Sans aucun signal faible, la confiance est **haute** ; avec un seul, **moyenne** ; avec plusieurs, **basse**. Ce niveau n'est pas une probabilité : c'est un compte de raisons de douter. Il sert à dire au médecin ce qu'il faut vérifier en premier.

Dans l'exemple. « Fièvre » est retirée par E2. « Pyélonéphrite » reste, mais toute relation qui l'affirme porte le signal « hypothèse » et une confiance abaissée. « Scanner thoracique → objective → foyer » n'a aucun signal faible : confiance haute.

Le mode précision : apprendre à peser les signaux

Son but. Le mode standard ne retire que ce qu'une règle claire condamne. Certains usages demandent davantage : préférer un graphe plus court mais plus sûr. Le mode précision offre ce réglage. Il retire en plus les éléments les plus douteux, en acceptant de perdre des éléments justes. C'est le compromis classique entre erreur et rejet : refuser de se prononcer quand le risque d'erreur est trop haut (Chow, 1970 ; Geifman et El-Yaniv, 2017).

Le problème à résoudre. On dispose de nombreux signaux, chacun imparfait. Lequel compte le plus ? Une relation répétée est-elle plus suspecte qu'une relation entre termes éloignés ? Personne ne peut le dire à l'avance. Il faut l'apprendre à partir d'exemples où l'on sait ce qui est juste.

Pourquoi une régression logistique. Trois raisons :

1. Elle est faite pour ce problème : combiner des indices oui/non pour estimer si un élément est juste (Cox, 1958).
2. Elle est **lisible** : elle donne un poids à chaque indice, et ce poids se lit directement (« cet indice rend l'élément plus souvent faux »). Un modèle opaque ne permettrait pas d'expliquer une décision au médecin.
3. Elle combine des signaux faibles imparfaits en un seul jugement, ce que la supervision faible a montré efficace (Ratner et al., 2017).

Comment elle fonctionne, étape par étape.

1. **De l'observation à l'indice.** Chaque observation des agents devient un indice qui vaut oui ou non : « la preuve existe », « les termes sont sur la même ligne », « la relation est répétée », « l'entité est un biomarqueur cité dans la biologie », et aussi les mots de la mention. Certains indices croisent deux informations (un type d'entité *dans* une section donnée), parce qu'un même type n'a pas la même fiabilité partout.
2. **De l'indice au poids.** Sur des exemples dont on connaît la réponse, le modèle ajuste peu à peu un poids par indice. Si les éléments qui portent un indice sont souvent faux, son poids devient négatif ; s'ils sont souvent justes, positif ; s'il ne distingue rien, il reste proche de zéro. Une pénalité empêche un poids de grossir sans raison sur un indice trop rare.
3. **Du poids au score.** Pour un nouvel élément, on additionne les poids de ses indices, puis on ramène cette somme entre zéro et un. Plus le score est haut, plus l'élément ressemble à ceux qui étaient justes.
4. **Du score à la décision.** On ne fixe pas un score à la main. On choisit **la part à garder** (par exemple « garder les quatre cinquièmes »), et le seuil s'en déduit : c'est le score sous lequel tombe la part la plus douteuse des exemples. Tout élément sous ce seuil est retiré ; ce sont les règles E4 (entités) et R4 (relations).

Pourquoi fixer une part plutôt qu'un score. Le score n'est pas une probabilité exacte. Une part se comprend directement (« on écarte les éléments les plus douteux ») et le choix de la part devient un réglage d'usage : plus on garde peu, moins il reste d'hallucinations, mais plus on perd d'éléments justes.

Ce que le modèle a appris. Ses poids confirment l'intuition clinique : une relation répétée ou qui suit une négation est plus souvent fausse ; une relation extraite directement, avec ses termes sur la même ligne, plus souvent juste ; un biomarqueur ou un signe vital accompagné de sa valeur est fiable, un antécédent cité dans les antécédents aussi. Les indices sont liés entre eux : un poids isolé se lit comme une tendance, pas comme une cause.

Sans modèle appris. Si aucun modèle n'a été entraîné, le mode précision retire simplement les relations de confiance basse.

Ce qu'il transmet. Le graphe final : chaque élément gardé porte son niveau de confiance, et chaque élément retiré porte la règle qui l'a retiré.

Temps 6 — Évaluer sans tricher

Étage 8 — Évaluation

La question à laquelle il répond. TRACE fait-il vraiment mieux, et à quel endroit ?

La règle d'or : un seul étage lit l'annotation de référence. L'annotation faite à la main et validée (le gold) n'est lue qu'ici. Aucun autre étage ne la consulte, et aucun ne dépend de ses résultats. Sinon, TRACE pourrait « apprendre les réponses » et paraître meilleur qu'il ne l'est sur un document nouveau.

Ce qu'il mesure, après chaque étage.

- **La précision** : parmi ce que le graphe affirme, quelle part est juste ?
- **Le rappel** : parmi ce qu'il fallait trouver, quelle part a été trouvée ?
- **Le F1** : un équilibre entre les deux.
- **Le taux d'hallucination** : la part de ce que le graphe affirme qui est faux. C'est le complément de la précision.
- **La structure**, sans regarder le gold : relations orphelines, non-conformités au guideline, doublons, termes absents du texte.

Mesurer après chaque étage permet de voir ce que chacun apporte, et de repérer un étage qui dégrade le résultat.

La stabilité. Les mêmes mesures sont faites séparément sur deux moitiés du corpus. Un effet qui n'apparaît que sur une moitié est un hasard, pas une amélioration.

La validation croisée : comment le mode précision est mesuré honnêtement

Le mode précision apprend des poids à partir d'exemples. Si on le mesurait sur les mêmes documents que ceux qui ont servi à l'apprendre, le résultat serait trop beau. On procède donc ainsi (Stone, 1974) :

1. Le corpus est coupé en deux moitiés.
2. Le modèle apprend sur la première moitié, puis l'arbitrage complet est appliqué et mesuré sur la seconde, qu'il n'a jamais vue.
3. On inverse les rôles.
4. On additionne les deux mesures.

Chaque document est ainsi jugé par un modèle qui ne l'a jamais vu : la mesure vaut pour des documents nouveaux. Le modèle livré à la fin est réappris sur tout le corpus.

La règle du seuil d'ajout

Cette règle explique pourquoi certains ajouts sont gardés et d'autres non, à la seconde passe comme à la récupération structurée.

L'idée. Ajouter un élément a deux effets contraires. S'il est juste, on trouve une chose de plus : le rappel monte. S'il est faux, on affirme une erreur de plus : la précision baisse. Un ajout n'améliore donc le résultat global que s'il est juste **assez souvent**.

Où se trouve ce « assez souvent ». Il se déduit de la définition du F1. Un ajout fait monter le F1 seulement s'il est juste plus souvent que **la moitié de la qualité actuelle** du graphe. Plus le graphe est déjà bon, plus les ajouts doivent être fiables pour l'améliorer encore. Pour les graphes de TRACE, cela revient à environ un ajout juste sur trois.

Comment la règle est appliquée sans tricher.

1. On regarde, sur une moitié du corpus, quels groupes d'ajouts (par type, par vote, par proximité des termes…) dépassent ce seuil.
2. On garde ces groupes, puis on mesure l'effet sur l'autre moitié.
3. On inverse les moitiés.
4. Un groupe n'est retenu que s'il améliore le résultat **sur les deux moitiés**.

Ce que la règle a donné.

- Seconde passe, entités : certains types dépassent le seuil des deux côtés et sont gardés.
- Seconde passe, relations : aucun groupe ne dépasse le seuil des deux côtés. Le seul filtre qui retenait quelque chose sur une moitié dégradait le résultat sur l'autre. Les relations ajoutées sont donc toutes écartées.

- Récupération structurée : relier un traitement à sa posologie sur la même ligne améliore le résultat des deux côtés et est gardé ; relier chaque traitement au patient le dégrade et a été abandonné.

Les autres seuils. Les seuils qui ne sont pas appris (ce qu'est une ligne, un paragraphe, la fenêtre avant une négation, la part de mots requise pour reconnaître un terme) sont fixés à l'avance d'après la forme des comptes rendus, et jamais ajustés en regardant le gold.

Ce que TRACE garantit, et ses limites

Ce que TRACE garantit.

- Tout élément gardé est retrouvé dans le texte du compte rendu ; tout ajout de TRACE est une copie du texte.
- Toute relation gardée est jugée par rapport aux signatures du guideline, et son écart éventuel est signalé.
- Un fait nié n'est jamais présenté comme affirmé.
- Chaque retrait a une règle nommée pour cause ; chaque élément gardé a un niveau de confiance expliqué.
- Aucune règle n'est réglée en regardant les réponses : ce qui est appris est mesuré sur des documents jamais vus.

Ses limites.

- **Le rappel dépend de l'extraction.** TRACE retire, répare et complète les parties à forme fixe, mais il ne peut pas retrouver une information du texte libre que le modèle n'a jamais vue. Pour aller plus loin, il faut agir à l'extraction.
- **Le mode précision coûte du rappel.** Retirer plus d'éléments douteux retire aussi des éléments justes. Le choix de la part gardée dépend de l'usage.
- **Un seul corpus.** Les règles sont validées sur deux moitiés indépendantes, mais pas encore sur les comptes rendus d'un autre centre.
- **Le niveau de confiance n'est pas une probabilité.** C'est un compte de raisons de douter.
- **Le guideline évolue.** La conformité au guideline et la réparation doivent toujours utiliser la même version que l'extraction et l'annotation ; elles doivent être mises à jour vers la version 2.0.
- **« Faux » veut dire « absent de l'annotation de référence ».** Quelques éléments comptés comme faux sont peut-être justes mais non annotés.

Références

Référence	Utilisée pour
Ji, Z. et al. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12).	Définir l'hallucination
Huang, L. et al. (2025). A Survey on Hallucination in Large Language Models. *ACM Transactions on Information Systems*, 43(2).	Fidélité et factualité
Min, S. et al. (2023). FActScore. *EMNLP 2023*.	Vérifier chaque affirmation contre la source
Kadavath, S. et al. (2022). Language Models (Mostly) Know What They Know. *arXiv:2207.05221*.	Confiance déclarée par le modèle
Wang, X. et al. (2023). Self-Consistency. *ICLR 2023*.	Accord entre plusieurs réponses
Manakul, P., Liusie, A. & Gales, M. (2023). SelfCheckGPT. *EMNLP 2023*.	Accord entre plusieurs réponses
Kamoi, R. et al. (2024). When Can LLMs Actually Correct Their Own Mistakes? *TACL*, 12.	Limites de l'auto-correction
Huang, J. et al. (2024). Large Language Models Cannot Self-Correct Reasoning Yet. *ICLR 2024*.	Limites de l'auto-correction
Kim, G. et al. (2022). OCR-free Document Understanding Transformer (Donut). *ECCV 2022*.	Lecture directe de l'image
Xu, Y. et al. (2020). LayoutLM. *KDD 2020*.	Lecture directe de l'image
Knublauch, H. & Kontokostas, D. (2017). Shapes Constraint Language (SHACL). *W3C Recommendation*.	Contraintes de forme
Ali, M., Taha, Z. & Morsey, M. M. (2026). Ontology-grounded knowledge graphs for mitigating hallucinations in LLMs for clinical question answering. *Journal of Biomedical Informatics*, 175.	Référentiel clinique contre les hallucinations
Paulheim, H. (2017). Knowledge Graph Refinement. *Semantic Web*, 8(3).	Raffinement des graphes

Référence	Utilisée pour
Chu, X., Ilyas, I. F. & Papotti, P. (2013). Holistic Data Cleaning. *ICDE 2013*.	Réparation sous contraintes
Rekatsinas, T. et al. (2017). HoloClean. *PVLDB*, 10(11).	Réparation sous contraintes
Fan, W., Wu, Y. & Xu, J. (2016). Functional Dependencies for Graphs. *SIGMOD 2016*.	Réparation sous contraintes
Gangemi, A. (2005). Ontology Design Patterns for Semantic Web Content. *ISWC 2005*.	Patrons de modélisation
Noy, N. & Rector, A. (2006). Defining N-ary Relations on the Semantic Web. *W3C Working Group Note*.	Lien représenté par un nœud
Chow, C. K. (1970). On Optimum Recognition Error and Reject Tradeoff. *IEEE Transactions on Information Theory*, 16(1).	Abstention
Geifman, Y. & El-Yaniv, R. (2017). Selective Classification for Deep Neural Networks. *NeurIPS 2017*.	Abstention
Du, Y. et al. (2024). Improving Factuality and Reasoning through Multiagent Debate. *ICML 2024*.	Débat entre modèles (contraste)
Savova, G. K. et al. (2010). cTAKES. *JAMIA*, 17(5).	Extraction clinique par règles
Fraile Navarro, D. et al. (2023). Clinical NER and relation extraction: a systematic review. *International Journal of Medical Informatics*, 177.	Extraction clinique par règles
Chapman, W. W. et al. (2001). NegEx. *Journal of Biomedical Informatics*, 34(5).	Négation
Harkema, H. et al. (2009). ConText. *Journal of Biomedical Informatics*, 42(5).	Hypothèse et temporalité
Ratner, A. et al. (2017). Snorkel. *PVLDB*, 11(3).	Combiner des signaux faibles
Cox, D. R. (1958). The Regression Analysis of Binary Sequences. *Journal of the Royal Statistical Society B*, 20(2).	Régression logistique

Référence	Utilisée pour
Stone, M. (1974). Cross-Validatory Choice and Assessment of Statistical Predictions. *Journal of the Royal Statistical Society B*, 36(2).	Validation croisée