TRACE — Comment TRACE réduit les hallucinations

Oct 21, 2026 · @Lamis

Le problème

TRACE part d'une idée simple : un modèle de langage ne doit être cru que lorsque le compte rendu et le guideline lui donnent raison. Tout ce qui suit découle de cette idée.

Le modèle (Mistral Small 4) lit les comptes rendus d'hospitalisation de patients septiques et en tire un graphe de connaissances : des **entités** (un diagnostic, un traitement, un biomarqueur…) et des **relations** entre elles (« ce traitement est administré au patient », « cette imagerie objective ce foyer »). Ce graphe doit pouvoir servir à des cliniciens. Or un modèle de langage produit parfois des éléments qui ne sont pas dans le document : ce sont les hallucinations.

Quelle hallucination TRACE combat. La littérature distingue deux familles (Ji et al., 2023 ; Huang et al., 2025) :

- l'hallucination de **factualité** : la sortie contredit la réalité du monde ;
- l'hallucination de **fidélité** : la sortie n'est pas soutenue par la source qu'on a donnée au modèle.

TRACE traite la seconde. La question n'est pas « est-ce médicalement vrai ? » mais « est-ce bien ce que dit *ce* compte rendu, sous la forme que demande *ce* guideline ? ».

Les cinq formes qu'elle prend dans un graphe clinique.

Forme	Ce qui se passe	Exemple
Entité inventée	Le modèle cite quelque chose qui n'est pas écrit, ou le reformule	un antibiotique jamais mentionné
Relation inventée	Deux entités réelles sont reliées par un lien que le texte n'établit pas	une imagerie reliée à un foyer qu'elle n'a pas montré
Mauvaise forme	L'information est juste mais mal rangée : deux informations fusionnées, une relation déguisée en entité, un lien qui ne respecte pas le guideline	« Augmentin 1 g x3/j » en une seule entité au lieu d'un traitement et de sa posologie

Forme	Ce qui se passe	Exemple
Contexte inversé	Un fait nié ou supposé est présenté comme affirmé	« pas de fièvre » devenu « fièvre »
Redondance	Le même fait apparaît plusieurs fois et gonfle le graphe	deux fois la même relation

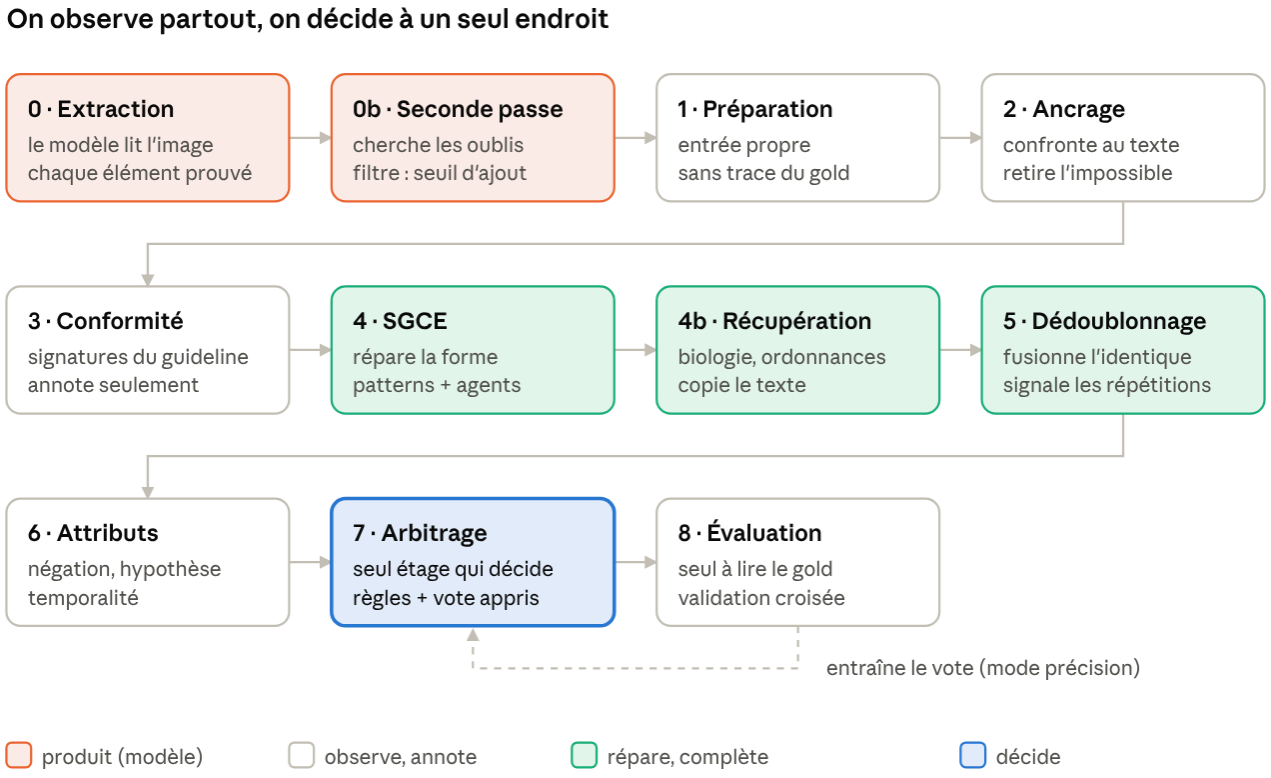
Chaque étage de TRACE répond à une ou plusieurs de ces formes. Le schéma de la section suivante montre lesquelles et dans quel ordre.

Le fil conducteur

TRACE fait passer le graphe par une suite d'étages. Chaque étage prend ce que le précédent lui transmet, répond à une seule question, et transmet au suivant un graphe enrichi de ses observations.

Étage	Question	Rôle sur le graphe
0 Extraction	Que contient le compte rendu ?	Produit les entités et relations
0b Seconde passe	Qu'a-t-on oublié ?	Ajoute ce qui passe le filtre
1 Préparation	L'entrée est-elle propre et honnête ?	Nettoie
2 Ancrage dans le texte	Est-ce écrit dans le compte rendu ?	Observe ; retire seulement l'impossible
3 Conformité au guideline	La relation a-t-elle la forme autorisée ?	Observe
4 SGCE	L'information est-elle bien rangée ?	Répare
4b Récupération structurée	Des éléments simples ont-ils été oubliés ?	Complète
5 Dédoublonnage	Le même fait est-il répété ?	Fusionne l'identique, signale le reste
6 Attributs cliniques	Le fait est-il présent, nié, supposé, passé ?	Observe
7 Arbitrage	Faut-il garder cet élément, avec quelle confiance ?	**Décide**

Étage	Question	Rôle sur le graphe
8 Évaluation	TRACE fait-il vraiment mieux, et où ?	Mesure ; seul à lire le gold



le parcours d'un compte rendu dans TRACE

On lit le schéma ligne par ligne, de gauche à droite. La flèche en pointillés indique que l'évaluation entraîne le vote utilisé par l'arbitrage en mode précision, toujours sur des documents que ce vote n'a pas vus.

Les quatre règles qui relient les étages.

1. **Deux références seulement.** Le texte du compte rendu dit ce qui est vrai pour ce patient ; le guideline dit sous quelle forme l'écrire. Rien d'autre ne sert à juger.
2. **Observer partout, décider à un seul endroit.** Les étages ne retirent que l'impossible ; ils notent le douteux. La décision est prise à l'arbitrage, avec toutes les observations réunies, et chaque retrait y reçoit une règle nommée.
3. **Rien n'est inventé par TRACE.** Tout ce que TRACE ajoute ou répare est recopié du texte. Un cas ambigu n'est pas corrigé.
4. **Le gold n'est lu qu'à la fin.** Aucune règle n'est réglée en regardant les réponses ; ce qui est appris est mesuré sur des documents jamais vus.

Un exemple suivi de bout en bout

Pour rendre le parcours concret, on suit un extrait de compte rendu (construit pour l'explication) et ce que devient chaque élément proposé par le modèle.

> **Antécédents** — HTA. Diabète de type 2.
>
> **Histoire de la maladie** — Suspicion de pyélonéphrite. Pas de fièvre à l'entrée.
>
> **Biologie** — Leucocytes 18.2 4.0-10.0 G/L
>
> **Conclusion** — Choc septique sur pneumopathie. Scanner thoracique : foyer lobaire inférieur droit.
>
> **Traitement de sortie** — Augmentin 1g x3/j

Élément proposé par le modèle	Problème	Ce que fait TRACE	Où
Entité « antibiothérapie adaptée »	N'est écrite nulle part	Retirée, avec ses relations	Ancrage dans le texte
Relation « HTA → facteur de risque de → choc septique »	Les deux termes sont écrits dans des parties éloignées ; le texte ne les relie pas	Retirée si les deux termes ne se rencontrent jamais à proximité ; sinon gardée avec une confiance abaissée	Ancrage, puis décision
Entité « Augmentin 1g x3/j » typée TRAITEMENT	Deux informations fusionnées	Séparée en un TRAITEMENT et une POSOLOGIE, reliés entre eux	Réparation de la forme (SGCE)
La ligne « Leucocytes … », oubliée par le modèle	Oubli	Ajoutée comme BIOMARQUEUR, recopiée de la ligne	Récupération structurée
La relation « Scanner thoracique → objective → foyer lobaire inférieur droit » proposée deux fois	Redondance	Une seule copie gardée	Dédoublonnage
Entité « fièvre »	Le texte dit « pas de fièvre »	Marquée niée, puis retirée	Qualification, puis décision

Élément proposé par le modèle	Problème	Ce que fait TRACE	Où
Entité « pyélonéphrite »	Le texte dit « suspicion de »	Marquée hypothétique ; gardée, mais signalée comme moins sûre	Qualification, puis décision
Relation « Scanner thoracique → objective → foyer » (la copie gardée)	Aucun	Gardée avec la confiance la plus haute : preuve dans le texte, termes sur la même ligne, conforme au guideline	Décision

On retrouve dans ce tableau les cinq formes d'hallucination, chacune traitée à un endroit précis du parcours. Les sections suivantes expliquent chaque endroit dans l'ordre.

Étage 0 — Extraction par le modèle

La question à laquelle il répond. Quelles entités et quelles relations le compte rendu contient-il ?

Comment ça se passe.

1. Chaque page est donnée au modèle sous forme d'image. Le modèle la lit directement, sans passer par un logiciel d'OCR séparé : il voit la mise en page (tableaux de biologie, titres de section), ce qu'un texte brut perdrait (Kim et al., 2022 ; Xu et al., 2020).
2. Le modèle extrait d'abord les **entités** de la page, avec les types définis par le guideline.
3. Il extrait ensuite les **relations** entre ces entités, en choisissant seulement parmi les relations que le guideline autorise.
4. Pour chaque élément, il doit fournir trois choses en plus : la **preuve** (le passage exact du texte qui le justifie), s'il est **nié** ou **hypothétique**, et son propre **niveau de confiance**.
5. Le modèle travaille en mode déterministe : le même document donne toujours la même extraction.

Pourquoi exiger une preuve. Une affirmation accompagnée de sa source peut être contrôlée. C'est l'idée de FActScore (Min et al., 2023) : découper la sortie en affirmations élémentaires et vérifier chacune contre la source. TRACE l'applique à chaque entité et à chaque relation.

Pourquoi demander une confiance au modèle. Les modèles de langage savent en partie quand ils se trompent (Kadavath et al., 2022). Ce doute déclaré sera réutilisé au moment de décider.

Ce qu'il transmet. Un graphe brut, où chaque élément porte sa preuve, sa négation, son hypothèse et sa confiance.

Étage 0b — Seconde passe

La question à laquelle il répond. Qu'est-ce que le modèle a oublié ?

Pourquoi cet étage existe. Un post-traitement peut retirer ou corriger, mais il ne peut pas deviner ce que le modèle n'a jamais extrait. Pour gagner en rappel, il faut redemander au modèle.

Comment ça se passe.

1. On redonne au modèle la page **et** la liste de ce qu'il a déjà extrait. On lui demande seulement ce qui manque : d'abord les entités, puis les relations.
2. Chaque demande est posée plusieurs fois. Un élément n'est retenu que s'il revient dans la majorité des réponses. Une réponse stable d'un essai à l'autre est plus souvent juste qu'une réponse isolée (Wang et al., 2023 ; Manakul et al., 2023).
3. Une entité ajoutée doit avoir sa preuve recopiée telle quelle de la page. Une relation ajoutée doit respecter le guideline et relier deux entités existantes.
4. Un **filtre** trie ensuite les ajouts.

Le filtre : pourquoi on garde certaines entités ajoutées, mais aucune relation ajoutée

D'abord, de quoi parle-t-on. La seconde passe propose des **ajouts** : des entités et des relations que l'extraction initiale n'avait pas. Le filtre décide quels ajouts entrent dans le graphe. Il ne touche **jamais** à l'extraction initiale : toutes ses entités et toutes ses relations sont conservées et passent dans la suite de TRACE.

Une comparaison : le QCM à points négatifs. Dans un QCM où une bonne réponse rapporte des points et une mauvaise en fait perdre, un étudiant prudent ne répond que s'il est **assez sûr**. S'il répond au hasard, il perd plus qu'il ne gagne. Les ajouts de la seconde passe fonctionnent de la même façon :

- un ajout **juste** rapporte : le graphe trouve une information de plus ;
- un ajout **faux** coûte : le graphe contient une hallucination de plus.

Un ajout ne vaut donc la peine que s'il est juste **assez souvent**. En dessous, il fait perdre plus qu'il ne fait gagner. Ce niveau minimal s'appelle ici le **seuil d'ajout** ; il est expliqué en détail à l'étage 8.

Comment le filtre décide, étape par étape.

1. On range les ajouts par groupes : par type d'entité ou de relation, selon que le modèle les a proposés dans toutes ses réponses ou seulement dans certaines, selon la distance entre les termes, etc.
2. Pour chaque groupe, on regarde si ses ajouts sont justes assez souvent pour dépasser le seuil.
3. On fait cette vérification sur deux moitiés du corpus, séparément. Un groupe n'est accepté que s'il dépasse le seuil **sur les deux** : sinon, c'était peut-être de la chance.
4. Les groupes acceptés entrent dans le graphe ; les autres sont écartés.

Ce que ça donne pour les entités. Certains groupes passent le seuil sur les deux moitiés : par exemple les micro-organismes, traitements, biomarqueurs et éléments d'évolution que le modèle a proposés dans **toutes** ses réponses et qui ne sont pas niés. Ce sont des éléments concrets, écrits tels quels dans le texte, que le modèle retrouve de façon stable. Ils sont gardés. Une entité proposée aussi par une seconde passe indépendante passe également le seuil pour certains types, et elle est gardée. Les autres entités ajoutées sont écartées.

Ce que ça donne pour les relations. On a regardé tous les groupes possibles. **Aucun** ne passe le seuil sur les deux moitiés. Même les meilleurs groupes de relations ajoutées sont justes trop rarement : les ajouter ferait perdre plus qu'elles ne rapportent. On les écarte donc toutes. C'est la même règle que pour les entités ; elle donne simplement un résultat différent.

Pourquoi les relations ajoutées sont si souvent fausses. Une entité est un mot écrit dans le texte : on peut le retrouver et le recopier. Une relation est un **lien** entre deux mots ; le modèle doit comprendre que le texte établit ce lien. Quand on lui demande « ce qui manque », il prend deux entités réelles du compte rendu et les relie par un lien qui paraît médicalement logique, mais que le texte n'écrit pas. Exemples : une coloscopie présentée comme ayant montré une sinusite ; une HTA présentée comme cause d'un choc septique, alors que le texte dit seulement « HTA mal équilibrée ». Chaque mot existe, mais le lien est inventé : c'est exactement une hallucination de relation.

Lien avec la littérature. Demander à un modèle de compléter sa propre sortie, sans information extérieure, apporte peu (Kamoi et al., 2024 ; Huang J. et al., 2024). Le résultat sur les relations confirme ce constat ; le gain sur les entités vient des filtres qui ajoutent un contrôle extérieur (la preuve recopiée, l'accord entre plusieurs réponses).

Ce qu'il transmet. Le graphe initial, enrichi des seules entités ajoutées qui ont passé le filtre.

Étage 1 — Préparation

La question à laquelle il répond. L'entrée est-elle propre et honnête ?

Comment ça se passe.

1. Il retire toute relation qui aurait été ajoutée ou validée, dans une version antérieure du travail, en regardant l'annotation de référence. Sans ce retrait, l'évaluation mesurerait l'annotation elle-même et non TRACE.
2. Il uniformise l'écriture des noms d'entités (certains caractères, comme le symbole « micro », existent sous deux formes qui se ressemblent). Les mentions telles qu'elles apparaissent dans chaque page restent, elles, identiques au texte, car elles seront comparées mot pour mot au texte plus tard.
3. Il donne un identifiant à chaque relation qui n'en a pas, pour que chaque étage puisse la suivre et la retirer sans ambiguïté.

Ce qu'il transmet. Un graphe propre, sans aucune trace de l'annotation de référence.

Étage 2 — Ancrage dans le texte

La question à laquelle il répond. Ce que dit le graphe est-il écrit dans le compte rendu ?

Comment on décide qu'un terme « est dans le texte ». Le texte et le terme sont mis sous une forme comparable (minuscules, sans accents, sans ponctuation). Le terme est reconnu s'il apparaît tel quel, ou si la plupart de ses mots porteurs de sens sont présents, en tolérant les accords et les pluriels. Une exigence s'ajoute : **tous les nombres** du terme doivent être dans le texte. Un libellé juste avec une valeur inventée reste une hallucination grave.

Ce qu'il observe pour chaque relation.

- **La preuve** : la citation donnée par le modèle existe-t-elle vraiment dans le texte ?
- **La distance** : les deux termes reliés apparaissent-ils sur la même ligne, dans le même paragraphe, ou jamais près l'un de l'autre ?
- **La section** : dans quelle partie du compte rendu la relation est-elle citée (antécédents, examen, biologie, évolution, conclusion…) ?

Pour chaque entité, il note si elle figure dans le document, et si elle figure **mot pour mot dans sa propre page**.

Ce qu'il retire : seulement l'impossible.

- une entité absente de tout le document (elle a été inventée), avec les relations qui en dépendent ;
- une relation dont une extrémité n'existe pas dans le texte ;
- une relation dont la citation de preuve n'existe pas dans le texte ;
- une relation dont les deux termes ne se rencontrent jamais à proximité l'un de l'autre : le texte ne peut pas les relier.

Pourquoi ne pas retirer davantage ici. Une relation dont les termes sont dans le même paragraphe mais pas sur la même ligne peut être juste ou fausse. La juger ici, avec une seule information, serait trancher trop tôt. Elle est notée et sera jugée à l'étage 7, avec tous les autres signaux.

Dans l'exemple. « Antibiothérapie adaptée » n'est écrite nulle part : elle est retirée ici. « HTA → facteur de risque de → choc septique » relie deux termes écrits dans des parties éloignées : si ces termes ne se rencontrent jamais à proximité, la relation est retirée ici.

Lien avec la littérature. C'est l'application directe de la définition de l'hallucination de fidélité : un contenu non soutenu par la source (Ji et al., 2023 ; Huang et al., 2025).

Étage 3 — Conformité au guideline

Cet étage s'appelait auparavant « validation ontologique ». Le nouveau nom décrit mieux ce qu'il fait : l'étage ne raisonne pas sur une ontologie au sens formel ; il compare chaque relation aux signatures définies dans le guideline TRACE-Sepsis.

La question à laquelle il répond. Chaque relation a-t-elle la forme que le guideline autorise ?

Ce qu'est une signature. Le guideline définit, pour chaque relation, le type d'entité attendu au départ et le type attendu à l'arrivée. Par exemple, « imagerie objective un foyer » part d'une IMAGERIE_PROCEDURE et arrive à un FOYER_INFECTIEUX.

Comment ça se passe. Pour chaque relation, l'étage pose trois questions et donne un statut :

1. La relation existe-t-elle dans le guideline ? Sinon : relation inconnue.
2. L'entité de départ a-t-elle le type attendu ? Sinon : départ non conforme.
3. L'entité d'arrivée a-t-elle le type attendu ? Sinon : arrivée non conforme.

Une relation qui passe les trois questions est **conforme**.

Pourquoi il ne retire rien. Deux raisons. D'abord, l'étage suivant peut réparer une relation non conforme (en la rattachant à la bonne entité ou en corrigeant un type). Ensuite, quand une relation est non conforme, c'est le plus souvent le **type d'une entité** qui est faux, alors que le lien lui-même est juste. Retirer la relation ferait perdre une information correcte. La non-conformité sera donc un signal de doute au moment de décider, pas un motif de retrait.

Lien avec la littérature. Déclarer séparément les contraintes de forme et les vérifier sur les données est le principe des langages de contraintes comme SHACL (Knublauch et Kontokostas, 2017). S'appuyer sur un référentiel clinique pour limiter les hallucinations est aussi la démarche d'Ali, Taha et Morsey (2026).

Étage 4 — SGCE : réparer la forme du graphe

La question à laquelle il répond. Le graphe a-t-il la bonne forme, celle que le guideline décrit ?

Ce qu'il cherche. Des **motifs d'erreur** connus, appelés *patterns*. Chacun décrit une façon typique dont un modèle range mal une information juste.

Famille	L'erreur de forme	Exemple	La réparation
A	Deux informations fusionnées dans une seule entité, ou un lien attendu qui manque	« Augmentin 1g x3/j » en une seule entité traitement	Séparer en deux entités et les relier
B	Une entité manque : une relation pointe vers une entité inexistante, ou une chaîne de deux relations a été raccourcie en une	une relation qui vise un identifiant absent	Rattacher à l'entité existante, ou créer l'entité si le texte la donne explicitement
C	Une relation a été extraite comme une entité	une « entité » qui décrit en réalité un lien entre deux choses	Remplacer cette entité par la relation correspondante
D	Une relation dont le départ ou l'arrivée n'a pas le type attendu par le guideline	un traitement relié là où le guideline attend un diagnostic	Rattacher autrement, corriger un type, ou retirer le lien invalide

Deux étapes complètent ces familles : la **réparation de relations** (remplacer une relation par celle qui correspond exactement aux types observés, quand il n'y en a qu'une) et la **résolution des relations orphelines** (rattacher une relation qui a perdu une extrémité à l'unique entité compatible, ou la retirer s'il n'y en a aucune).

Comment ça se passe, pour chaque pattern. Toujours les quatre mêmes étapes :

1. **Détecter** : lister les cas candidats, sans rien modifier.
2. **Valider** : ne garder que les cas où une seule correction est possible et où le texte la soutient ; les autres sont classés ambigus.
3. **Corriger** : appliquer seulement les corrections validées.
4. **Contrôler** : vérifier que la correction n'a rien cassé.

Un cas ambigu n'est **jamais** corrigé à ce stade.

Le multi-agent : un second avis pour les cas ambigus. « Le symbolique tranche d'abord » : les agents ne voient que les cas que les patterns ont détectés sans pouvoir choisir une correction sûre.

1. Des agents spécialisés, un par famille, proposent une action en regardant le graphe et le texte.
2. Les cas encore indécis passent devant un arbitre, qui fait voter trois points de vue indépendants : **le texte** soutient-il l'action ? **le guideline** est-il respecté après l'action ? **la cohérence clinique** locale est-elle préservée ?
3. L'action est appliquée si les trois sont d'accord, ou si deux sont d'accord sans opposition ferme du troisième et avec une preuve explicite dans le texte. Sinon, on **s'abstient** : rien n'est changé.

Ces agents ne sont pas des modèles de langage : ce sont des règles explicites. C'est un choix voulu. Faire débattre plusieurs modèles de langage (Du et al., 2024) risque de faire valider une erreur que tous partagent ; des agents à règles donnent des décisions reproductibles et explicables.

D'où vient l'idée. SGCE réunit quatre courants de la littérature :

- le **raffinement de graphes** après leur construction, pour détecter et corriger les erreurs (Paulheim, 2017) ;
- la **réparation de données sous contraintes**, qui corrige les violations en tenant compte de leur contexte plutôt qu'une par une (Chu, Ilyas et Papotti, 2013 ; Rekatsinas et al., 2017 ; Fan, Wu et Xu, 2016) ;
- les **patrons de modélisation**, en particulier la représentation d'un lien par un nœud, à l'origine de la famille C (Gangemi, 2005 ; Noy et Rector, 2006) ;
- l'**abstention** quand le risque d'erreur est trop élevé (Chow, 1970 ; Geifman et El-Yaniv, 2017).

L'apport de SGCE est d'assembler ces idées pour les erreurs de forme d'un graphe clinique produit par un modèle de langage, avec le guideline comme référence.

Ce qu'il transmet. Un graphe remis en forme. Chaque relation créée par SGCE est marquée comme telle, pour être contrôlée à l'étage 7.

Étage 4b — Récupération structurée

La question à laquelle il répond. Le modèle a-t-il oublié des éléments faciles à retrouver sans lui ?

Pourquoi c'est possible sans modèle. Certaines parties d'un compte rendu ont une forme fixe. Une ligne de biologie s'écrit toujours « libellé, valeur, normes, unité » ; une ligne d'ordonnance s'écrit « médicament, puis posologie ». Une règle simple suffit à les lire.

Comment ça se passe.

1. Dans la biologie, chaque ligne de cette forme que le modèle n'a pas extraite devient un biomarqueur.
2. Dans les traitements habituels et la prescription de sortie, chaque ligne devient un traitement et sa posologie.
3. Sur une même ligne d'ordonnance, le traitement est relié à sa posologie.

Les garde-fous. Rien n'est inventé : chaque ajout est un morceau de ligne recopié du texte. On n'ajoute rien qu'une entité existante couvre déjà. Les lignes qui ressemblent à de la biologie mais n'en sont pas (valeurs témoins du laboratoire, réglages du ventilateur) sont ignorées. Une règle qui aurait relié chaque traitement au patient a été testée puis abandonnée, parce qu'elle dégradait le résultat.

Lien avec la littérature. C'est l'approche des systèmes cliniques à règles pour les parties semi-structurées des documents (Savova et al., 2010 ; Fraile Navarro et al., 2023).

Dans l'exemple. La ligne « Leucocytes … », oubliée par le modèle, est ajoutée comme biomarqueur.

Étage 5 — Dédoublonnage

La question à laquelle il répond. Le graphe dit-il la même chose plusieurs fois ?

Comment ça se passe.

1. Deux entités strictement identiques (même type, même nom, même page, même preuve, même valeur…) sont fusionnées ; leurs relations sont reportées sur l'entité gardée.
2. Deux relations strictement identiques (mêmes entités, même type) : une seule est gardée.
3. Une relation qui répète un fait déjà présent sous d'autres identifiants est seulement **signalée**, pas retirée.

Pourquoi ne pas retirer les répétitions. Un compte rendu peut citer deux fois le même fait, à l'entrée et à la sortie par exemple. La répétition devient un signal de doute pour l'étage 7.

Étage 6 — Attributs cliniques

La question à laquelle il répond. Ce terme décrit-il un fait **présent**, **nié**, **supposé**, ou **passé** ?

Pourquoi c'est indispensable. Dans un compte rendu, la présence d'un mot ne veut pas dire que le patient a ce qu'il désigne. « Pas de fièvre » contient le mot fièvre ; « suspicion de pyélonéphrite » ne pose pas le diagnostic ; un antécédent ne décrit pas le séjour actuel. Un graphe qui ignore ce contexte affirme des choses que le texte n'affirme pas : c'est une hallucination par inversion.

Comment ça se passe. Pour chaque entité, l'étage regarde le texte juste avant la mention et la partie du compte rendu où elle se trouve.

Attribut	Comment il est déterminé
Négation	Un déclencheur de négation (« pas de », « absence de », « aucun », « sans », « éliminé », « non retrouvé »…) se trouve **juste avant** la mention ; ou le modèle lui-même l'a marquée niée
Hypothèse	Même mécanisme avec des déclencheurs d'incertitude (« suspicion de », « probable », « évoqué », « à éliminer », « à discuter »…)
Temporalité	D'après la section : antérieur (antécédents, traitements habituels), sortie (prescription de sortie), ou séjour
Unité	Pour une valeur chiffrée sans unité, l'unité écrite dans le nom est renseignée

Pourquoi le déclencheur doit toucher la mention. Le mot de négation doit être le dernier avant la mention. Dans « pas de fièvre, CRP élevée », la fièvre est niée mais pas la CRP. Une fenêtre trop large nierait à tort tout ce qui suit.

Pourquoi il ne retire rien. Comme les étages 2 et 3, il observe et note. La décision revient à l'étage 7, où la négation retire une entité et où l'hypothèse devient un signal de doute.

Lien avec la littérature. La détection de la négation par déclencheurs proches de la mention vient de NegEx (Chapman et al., 2001) ; l'ajout de l'hypothèse et de la temporalité vient de ConText (Harkema et al., 2009). Ces algorithmes qualifient des mentions mais n'agissent pas sur un graphe. TRACE va plus loin : les attributs servent directement à décider du sort des **entités et des relations**.

Dans l'exemple. « Fièvre » est marquée niée ; « pyélonéphrite » est marquée hypothétique ; « HTA » et « diabète de type 2 » sont marqués antérieurs.

Ce qu'il transmet. Un graphe complet où chaque élément porte toutes ses observations : celles du texte, du guideline, de la réparation, de la redondance et du contexte. Tout est prêt pour décider.

Étage 7 — Arbitrage

La question à laquelle il répond. Pour chaque entité et chaque relation du graphe : faut-il la garder ? Et si on la garde, avec quel degré de confiance ?

Pourquoi un seul étage décide. Jusqu'ici, les étages ont observé et noté ; ils n'ont retiré que l'impossible. Si chaque étage retirait selon son propre critère, un élément pourrait être condamné sur une seule information, sans tenir compte des autres, et on ne saurait plus dire pourquoi il a disparu. En réunissant toutes les observations au même endroit :

- chaque décision est prise en voyant **tout** ce qu'on sait de l'élément ;
- chaque retrait a **une règle nommée** pour cause ;
- la décision est écrite à côté de l'élément, ce qui permet de l'expliquer au médecin et de la vérifier.

Ce que l'étage 7 reçoit

Chaque élément arrive avec les observations faites par les étages précédents.

Observation	Faite à	Ce qu'elle dit
Présence mot pour mot dans la page	Étage 2	La mention est-elle recopiée du texte ou reformulée ?
Preuve, distance, section	Étage 2	La citation existe-t-elle ? Les deux termes sont-ils proches ? Dans quelle partie du compte rendu ?
Conformité au guideline	Étage 3	La relation respecte-t-elle sa signature ?
Création par SGCE	Étage 4	La relation a-t-elle été créée pendant la réparation ?
Répétition	Étage 5	Le même fait est-il déjà présent ailleurs ?
Négation, hypothèse, temporalité	Étage 6	Le fait est-il nié, supposé, antérieur ?
Confiance déclarée, mode d'obtention	Étage 0	Le modèle était-il sûr ? L'élément a-t-il été extrait directement ou déduit ?

Les cinq agents

Ces observations sont lues par cinq **agents**. Un agent est un lecteur spécialisé : il regarde un seul aspect de l'élément et rend un avis. Ce sont des règles explicites, pas des modèles de langage : le même élément reçoit toujours le même avis, et chaque avis peut être expliqué.

Agent	Ce qu'il regarde	Ce qu'il peut signaler
Ancrage	La preuve, la distance entre les termes, la section	Preuve non citée, termes éloignés
Conformité au guideline	La signature de la relation, **recalculée** ici car SGCE a pu changer les liens	Relation non conforme
Redondance	La répétition du fait	Doublon
Contexte	La négation, l'hypothèse, la temporalité de l'entité concernée	Fait nié, fait supposé
Provenance	L'origine de l'élément : extraction directe, déduction, réparation	Élément déduit, élément créé par SGCE

Le déroulement, dans l'ordre

1. **Décider des entités** (règles E1, E2, E3).
2. **Retirer en cascade** les relations des entités retirées.
3. **Décider des relations** restantes (règles R2, R3).
4. **Donner un niveau de confiance** à chaque relation gardée.
5. **En mode précision seulement**, retirer en plus les éléments les plus douteux (règles E4, R4).

Les entités passent en premier parce qu'une relation ne peut pas exister sans ses deux entités : il faut savoir quelles entités restent avant de juger les liens.

Étape 1 — Décider des entités

Une entité est retirée si **au moins une** de ces trois règles s'applique. Ces règles ont été fixées à l'avance, sans regarder l'annotation de référence.

E1 — L'entité ne figure pas mot pour mot dans le texte de sa page.

- *Ce que ça repère* : le modèle a reformulé (« insuffisance rénale aiguë » au lieu de « IRA » écrit dans le texte), résumé, ou inventé.

- *Pourquoi retirer* : une mention qui n'est pas dans le texte n'est pas fidèle à la source. On ne peut plus la retrouver ni la vérifier.
- *Différence avec l'étage 2* : l'étage 2 retirait ce qui est absent de **tout** le document ; E1 est plus exigeant et demande la forme exacte dans **la page** où l'entité a été extraite.

E2 — L'entité est niée.

- *Ce que ça repère* : « pas de fièvre », « absence d'épanchement », ou une entité que le modèle lui-même a marquée niée.
- *Pourquoi retirer* : un fait absent n'est pas une caractéristique du patient. Le garder dans le graphe ferait dire au graphe le contraire du texte.

E3 — Le modèle a déclaré une confiance moyenne ou faible.

- *Ce que ça repère* : les entités sur lesquelles le modèle a lui-même exprimé un doute au moment de l'extraction.
- *Pourquoi retirer* : un modèle de langage sait en partie quand il se trompe (Kadavath et al., 2022). Ignorer ce doute reviendrait à croire le modèle plus qu'il ne se croit lui-même.

Étape 2 — La cascade

Quand une entité est retirée, les relations qui la touchent n'ont plus de sens : un lien vers quelque chose qui n'existe plus est un lien vide. Elles sont donc retirées avec elle. Deux précisions importantes :

- **Une relation n'est retirée que si l'entité a disparu de toutes les pages.** Une même entité peut être citée sur plusieurs pages. Si elle est retirée d'une page (par exemple parce qu'elle y était reformulée) mais reste présente sur une autre, elle existe toujours dans le graphe, et ses relations restent.
- **La cascade va dans un seul sens.** Retirer une relation ne retire jamais une entité : une entité peut être juste sans être reliée à rien (un biomarqueur cité seul, par exemple).

Étape 3 — Décider des relations

Une relation est retirée si l'une de ces règles s'applique. Leur numérotation reprend celle de l'implémentation.

R2 — La relation affirme une entité que le modèle a lui-même marquée niée.

- *Exemple* : « patient → présente le symptôme → fièvre », alors que le modèle a noté que la fièvre était niée.
- *Pourquoi retirer* : l'extraction se contredit elle-même ; la relation affirme ce que l'entité nie.

R3 — La relation a été créée par SGCE et n'est pas ancrée dans le texte.

- *Ce que ça repère* : une réparation de l'étage 4 qui a produit un lien que le texte ne soutient pas (extrémité absente, preuve absente, termes jamais proches).
- *Pourquoi retirer* : une réparation ne doit pas échapper au contrôle qu'on impose à l'extraction. Les relations créées par SGCE n'existaient pas encore à l'étage 2 ; l'étage 7 leur applique donc les mêmes règles d'ancrage.

Ce qui n'est volontairement pas un motif de retrait.

- *La non-conformité au guideline.* Quand une relation ne respecte pas sa signature, c'est le plus souvent le type d'une entité qui est faux, alors que le lien est juste. Retirer la relation ferait perdre une information correcte.
- *L'hypothèse.* « Suspicion de pyélonéphrite » est une information clinique utile : le médecin a envisagé ce diagnostic. Elle est gardée, mais signalée.
- *La distance seule ou la répétition seule.* Une relation peut être juste même si ses termes sont dans le même paragraphe plutôt que sur la même ligne, ou si le compte rendu cite deux fois le même fait.

Ces éléments deviennent des **signaux faibles** : ils ne retirent pas, mais ils abaissent la confiance.

Étape 4 — Le niveau de confiance

Chaque relation gardée est examinée à la recherche de sept signaux faibles.

Signal faible	Ce qu'il indique	Pourquoi c'est un doute et pas un retrait
Preuve non citée	Le modèle n'a pas donné de passage du texte	La relation peut être juste, mais elle n'est pas démontrée
Termes éloignés	Les deux termes sont dans le même paragraphe mais pas sur la même ligne, ou introuvables ensemble	Un paragraphe peut relier deux faits, mais le lien est moins direct
Élément déduit	La relation n'a pas été extraite directement du texte	Une déduction peut être juste, mais elle ajoute une étape de raisonnement
Doublon	Le même fait est déjà présent	Le compte rendu peut répéter un fait
Négation proche	Un mot de négation précède l'entité dans le texte	Le déclencheur peut ne pas porter sur cette entité

Signal faible	Ce qu'il indique	Pourquoi c'est un doute et pas un retrait
Hypothèse	L'entité est supposée	C'est une information clinique, mais pas un fait établi
Non conforme au guideline	La relation ne respecte pas sa signature	Souvent, seul le type d'une entité est faux

La règle. Aucun signal faible : confiance **haute**. Un seul : confiance **moyenne**. Plusieurs : confiance **basse**.

Ce que ce niveau est, et ce qu'il n'est pas. C'est un compte de raisons de douter, lisible par un clinicien : « cette relation est en confiance basse parce que sa preuve n'est pas citée et que ses termes sont éloignés ». Ce n'est pas une probabilité. Son usage est pratique : il dit au médecin quelles relations vérifier en premier.

Étape 5 — Le mode précision

Pourquoi un second mode. Le mode standard ne retire que ce qu'une règle claire condamne. Il garde donc des éléments douteux qui ne déclenchent aucune règle. Certains usages demandent un graphe plus court mais plus sûr : par exemple, alimenter un outil d'aide à la décision, où une erreur coûte plus cher qu'un oubli. Le mode précision offre ce réglage : il retire **en plus** les éléments les plus douteux, en acceptant de perdre quelques éléments justes. C'est le compromis classique entre erreur et rejet : mieux vaut s'abstenir quand le risque d'erreur est trop élevé (Chow, 1970 ; Geifman et El-Yaniv, 2017).

Le problème à résoudre. Pour trouver « les plus douteux », il faut combiner tous les signaux. Mais lequel compte le plus ? Une relation répétée est-elle plus suspecte qu'une relation entre termes éloignés ? Un traitement cité dans l'examen clinique est-il plus fiable qu'un traitement cité dans la prescription de sortie ? Personne ne peut le dire à l'avance. Il faut l'**apprendre** sur des exemples dont on connaît la réponse.

L'outil choisi : la régression logistique. Pour trois raisons :

1. Elle est faite exactement pour ce problème : estimer si un élément est juste à partir d'indices de type oui/non (Cox, 1958).
2. Elle est **lisible** : elle attribue un poids à chaque indice, et ce poids se lit directement. On peut donc expliquer au médecin pourquoi un élément a été jugé douteux, ce qu'un modèle opaque ne permettrait pas.
3. Elle combine des signaux faibles et imparfaits en un seul jugement, ce que la supervision faible a montré efficace (Ratner et al., 2017).

Les indices utilisés. Chaque observation devient un indice qui vaut oui ou non. Il y a deux modèles séparés, car on ne juge pas une entité et une relation sur les mêmes bases.

Pour une entité	Pour une relation
Son type (biomarqueur, traitement, foyer…)	Le type de relation
La section où elle est citée	La preuve (citée ou non, retrouvée ou non)
Son type **dans** cette section	La distance entre les termes
Si elle est reliée à une autre entité	La section, et le type de relation **dans** cette section
Sa longueur (courte, moyenne, longue)	La conformité au guideline
Si elle contient un chiffre	La provenance (directe, déduite, réparée)
Si elle est répétée, si elle est supposée	La répétition, la négation, l'hypothèse, la temporalité
Son origine (extraction directe, récupération…)	
Les mots de la mention	Les mots de l'entité concernée

Les indices croisés (un type *dans* une section) sont nécessaires parce qu'un même type n'a pas la même fiabilité partout : un traitement cité dans les traitements habituels n'a pas le même statut qu'un traitement cité dans l'examen clinique.

Comment le modèle apprend, étape par étape.

1. **De l'observation à l'indice.** Chaque élément est décrit par la liste de ses indices « oui ».
2. **De l'indice au poids.** Le modèle part de poids nuls. Il parcourt les exemples de l'apprentissage et ajuste les poids peu à peu : si les éléments qui portent un indice sont souvent faux, le poids de cet indice descend ; s'ils sont souvent justes, il monte ; s'il ne distingue rien, il reste proche de zéro. Une pénalité freine les poids des indices trop rares, pour qu'un mot vu une seule fois ne décide pas à lui seul.
3. **Du poids au score.** Pour un nouvel élément, on additionne les poids de ses indices, puis on ramène la somme entre zéro et un. Un score haut veut dire : cet élément ressemble à ceux qui étaient justes.
4. **Du score à la décision.** On ne choisit pas un score limite à la main. On choisit **la part à garder** (par exemple « garder les quatre cinquièmes des éléments »). Le seuil s'en déduit : c'est le score sous lequel tombe la part la plus douteuse des exemples d'apprentissage. Tout élément sous ce seuil est retiré.

Les règles E4 et R4. Ce retrait par le vote s'appelle E4 pour les entités et R4 pour les relations. Il s'ajoute aux règles du mode standard, il ne les remplace pas. Pour les entités, le vote ne juge que celles qui ont passé E1, E2 et E3 : il trie parmi ce que les règles ont jugé acceptable.

Pourquoi choisir une part plutôt qu'un score. Le score n'est pas une probabilité exacte ; un score limite à la main serait arbitraire. Une part se comprend directement (« on écarte les éléments les plus douteux »). Le choix de la part devient un réglage d'usage : plus on garde peu, moins il reste d'hallucinations, mais plus on perd d'éléments justes.

Ce que le modèle a appris. Ses poids rejoignent l'intuition clinique :

- une relation **répétée**, ou dont l'entité suit une **négation**, est plus souvent fausse ;
- une relation **extraite directement**, avec ses termes **sur la même ligne**, est plus souvent juste ;
- un **biomarqueur** ou un **signe vital accompagné de sa valeur** est fiable, de même qu'un **antécédent cité dans les antécédents** ;
- un **traitement accompagné d'un chiffre** est plus souvent faux (probablement parce que la dose y est fusionnée avec le médicament).

Les indices sont liés entre eux ; un poids isolé se lit comme une tendance, pas comme une cause.

Sans modèle appris. Si aucun modèle n'a encore été entraîné, le mode précision se contente de retirer les relations de confiance basse.

Le mode précision, pas à pas

En une phrase. Le mode précision, c'est le mode standard **plus une étape de tri** : après les règles, chaque élément encore présent reçoit un score, et les éléments au score le plus bas sont retirés.

Deux graphes livrés. TRACE part de la même sortie de l'étage 6 et produit deux graphes : un en mode standard, un en mode précision. On choisit celui qui convient à l'usage : le graphe standard pour garder le plus d'informations, le graphe précision quand une erreur coûte plus cher qu'un oubli.

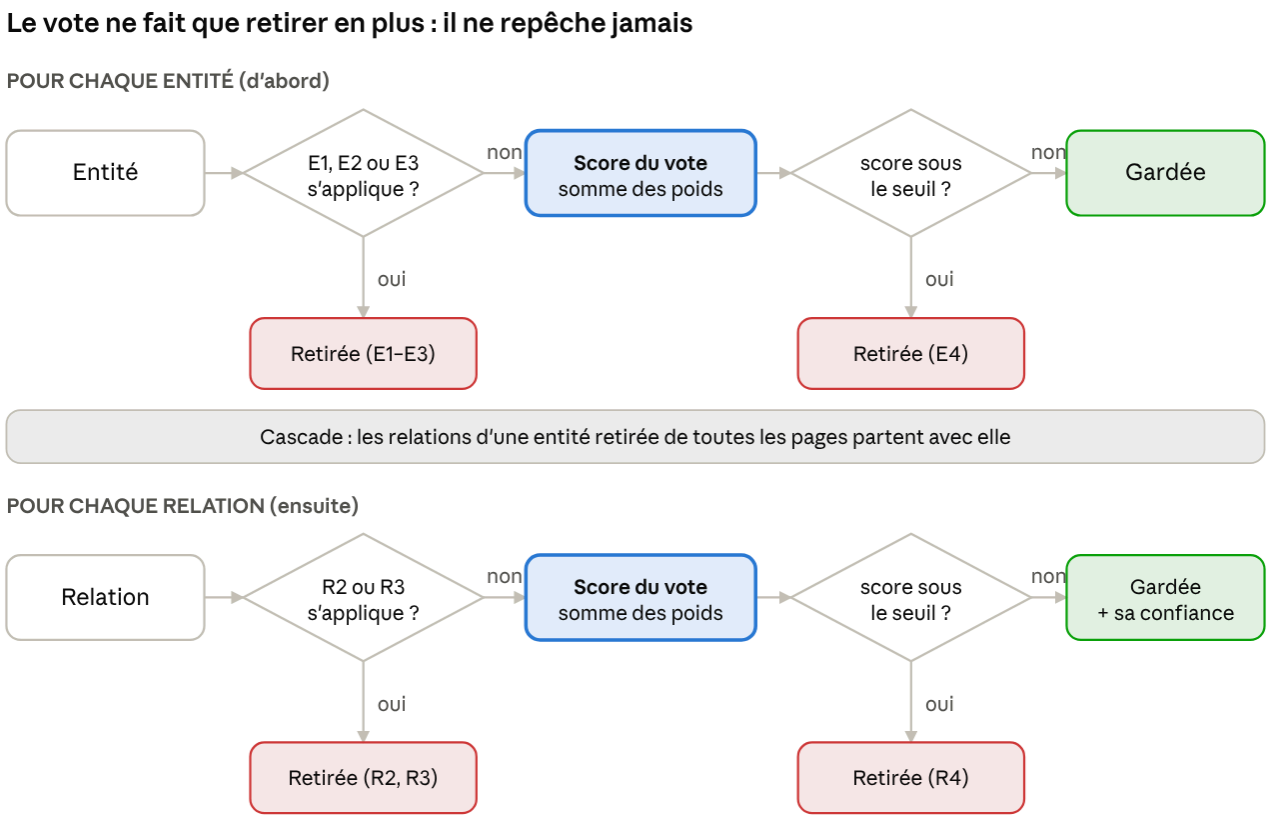
Avant : l'entraînement, une fois

Le vote doit d'abord apprendre. C'est l'étage 8 qui s'en charge, parce que c'est le seul à lire le gold (voir l'étage 8). Il produit un fichier qui contient deux choses :

- **les poids** : pour chaque indice, un nombre qui dit s'il pousse vers « juste » (positif) ou vers « faux » (négatif), et avec quelle force ;
- **les seuils** : pour chaque part à garder possible, le score limite correspondant.

Une fois ce fichier produit, l'étage 7 l'utilise sans jamais regarder le gold.

Pendant : le parcours d'un élément



parcours d'un élément en mode précision

Pour chaque entité, dans cet ordre :

1. On applique les règles E1, E2 et E3, exactement comme en mode standard. Si l'une s'applique, l'entité est retirée et le vote n'est même pas consulté.
2. Sinon, on fait la liste de ses indices « oui » : son type, sa section, son type dans cette section, si elle est reliée, sa longueur, si elle contient un chiffre, ses mots…
3. On additionne les poids de ces indices, puis on ramène la somme entre zéro et un : c'est son **score**.
4. On compare ce score au seuil de la part choisie.
5. Si le score est **sous** le seuil, l'entité est retirée par la règle **E4**. Sinon, elle est gardée.

Puis la cascade, comme en mode standard : les relations d'une entité retirée de toutes les pages partent avec elle.

Pour chaque relation restante :

1. On applique les règles R2 et R3, comme en mode standard.

2. On calcule son score de la même façon, avec les indices propres aux relations : type de relation, preuve, distance, section, conformité au guideline, provenance, répétition, négation, hypothèse, mots…
3. Si le score est sous le seuil, la relation est retirée par la règle **R4**.
4. Chaque relation gardée reçoit son niveau de confiance (haute, moyenne, basse), comme en mode standard.

Un exemple déroulé

On reprend l'exemple du compte rendu. Les effets indiqués sont ceux que le vote a appris ; on les décrit par leur sens plutôt que par leur valeur.

Élément	Ses principaux indices	Ce que chacun fait au score	Résultat
Relation « Scanner thoracique → objective → foyer lobaire inférieur droit »	extraite directement ; termes sur la même ligne	les deux poussent vers « juste »	Score haut, au-dessus du seuil : **gardée**
Relation répétant un fait déjà présent, dont l'entité suit une négation	doublon ; négation	les deux poussent nettement vers « faux »	Score bas, sous le seuil : **retirée par R4**
Entité « Leucocytes 18.2 4.0-10.0 G/L »	biomarqueur ; contient sa valeur ; dans la biologie	poussent vers « juste »	**Gardée**
Entité traitement contenant une dose, sur une ligne où la posologie a été fusionnée	traitement avec un chiffre	pousse vers « faux »	Si rien d'autre ne compense : **retirée par E4**

C'est le cumul qui compte : un élément peut porter un indice défavorable et rester au-dessus du seuil si ses autres indices sont très favorables.

Comment se lit le seuil

Imaginons tous les éléments d'apprentissage rangés du score le plus bas au plus haut. Choisir de garder les quatre cinquièmes, c'est couper la file à l'endroit où commence le cinquième le plus bas. Le score à cet endroit est le **seuil**. Un nouvel élément est comparé à ce point de coupe : en dessous, il ressemble aux éléments les plus douteux, et il est retiré.

Comment choisir la part à garder

Part gardée	Effet sur les hallucinations	Effet sur les oublis	Usage
Presque tout	Légère baisse	Presque aucun oubli ajouté	Améliorer sans rien perdre
Les quatre cinquièmes (défaut)	Nette baisse	Quelques éléments justes perdus	Bon compromis
Moins	Baisse encore plus forte	Beaucoup d'éléments justes perdus	Quand toute erreur est inacceptable

Le choix ne se fait pas à l'aveugle : l'étage 8 mesure l'effet de chaque part sur des documents que le vote n'a jamais vus (validation croisée).

Ce que le mode précision garantit

- **Il ne repêche jamais.** Un élément retiré par une règle du mode standard reste retiré. Le graphe précision est donc toujours contenu dans le graphe standard.
- **Il ne crée rien et ne corrige rien.** Il n'ajoute aucun élément, ne change aucun type, ne modifie aucun lien : il trie seulement.
- **Il reste explicable.** Pour un élément retiré par E4 ou R4, on peut lister les indices qui ont fait baisser son score.

Ce que l'étage 7 écrit pour chaque élément

Rien n'est retiré en silence. Chaque entité et chaque relation porte la trace de la décision :

- la décision (gardée ou retirée) ;
- les règles qui ont causé le retrait, s'il y en a ;
- pour une relation gardée, son niveau de confiance et la liste de ses signaux faibles ;
- en mode précision, le score du vote ;
- le mode utilisé.

C'est cette trace qui rend TRACE explicable : pour tout élément, on peut dire pourquoi il est là, ou pourquoi il n'y est plus.

Dans l'exemple

Élément	Décision	Pourquoi
Entité « fièvre »	Retirée	E2 : le texte dit « pas de fièvre »
Relation « patient → présente → fièvre »	Retirée	Cascade : son entité a disparu
Entité « pyélonéphrite »	Gardée	Hypothèse : information utile, mais signalée
Relation « patient → a pour diagnostic → pyélonéphrite »	Gardée, confiance moyenne	Un signal faible : hypothèse
Relation « Scanner thoracique → objective → foyer lobaire inférieur droit »	Gardée, confiance haute	Preuve citée, termes sur la même ligne, conforme, extraite directement

Ce que l'étage 7 transmet

Le graphe final. Chaque élément gardé porte son niveau de confiance ; chaque élément retiré porte la règle qui l'a retiré. C'est ce graphe que l'étage 8 évalue.

Étage 8 — Évaluation

La question à laquelle il répond. TRACE fait-il vraiment mieux que le modèle seul ? Et quel étage apporte quoi ?

Son second rôle. Il entraîne le vote du mode précision de l'étage 7, et mesure ce vote honnêtement.

La règle d'or : un seul étage lit le gold

Le **gold** est l'annotation de référence : les entités et relations annotées à la main sur les comptes rendus, selon le guideline, et validées. C'est la « bonne réponse ».

Seul l'étage 8 le lit. Aucun autre étage ne le consulte, et aucun ne dépend de ce que l'étage 8 mesure. La raison : si un étage pouvait regarder la bonne réponse, il pourrait s'y adapter, et TRACE paraîtrait meilleur sur ces documents qu'il ne le serait sur un compte rendu nouveau. C'est aussi pour cela que l'étage 1 retire tout ce qui aurait été produit autrefois avec l'aide du gold.

Comment on compare le graphe au gold

Pour chaque document, chaque élément produit par TRACE est rapproché d'un élément du gold.

Pour une entité, on cherche dans la même page une entité du gold, par degrés de tolérance successifs :

1. même texte et même type ;
2. sinon, l'un des textes contient l'autre (« choc septique » et « choc septique réfractaire »), avec le même type ;
3. sinon, des textes très proches (une faute, un accent, un pluriel), avec le même type ;
4. sinon, le même texte avec un **autre type** : c'est un **mauvais type**.

Pour une relation, il faut le même type de relation et des extrémités qui correspondent, avec la même tolérance sur le texte.

Ce rapprochement tolérant (appelé *souple*) évite de compter comme faux un élément juste écrit légèrement autrement. Chaque élément du gold ne peut être rapproché qu'une seule fois.

Les quatre issues possibles.

Issue	Ce que c'est	Ce que ça veut dire
Juste	Un élément produit qui correspond au gold	TRACE a trouvé une vraie information
Faux	Un élément produit sans correspondant dans le gold	Une hallucination (ou un oubli d'annotation, voir les limites)
Oubli	Un élément du gold que TRACE n'a pas produit	Une information manquée
Mauvais type	La bonne mention, avec un type faux	Compté à la fois comme faux et comme oubli

Ce que l'étage 8 mesure

Mesure	Question posée	Comment la lire
Précision	Parmi ce que le graphe affirme, quelle part est juste ?	Haute : le graphe dit peu de choses fausses
Rappel	Parmi ce qu'il fallait trouver, quelle part a été trouvée ?	Haut : le graphe oublie peu

Mesure	Question posée	Comment la lire
F1	Quel est l'équilibre entre les deux ?	Il ne monte que si précision et rappel sont bons ensemble
Taux d'hallucination	Quelle part de ce que le graphe affirme est fausse ?	C'est le complément de la précision ; c'est la mesure que TRACE cherche à faire baisser

Ces mesures sont calculées **séparément pour les entités et pour les relations**, car TRACE ne les traite pas de la même façon et leurs difficultés sont différentes.

Mesurer après chaque étage. Les mesures sont refaites à la sortie de **chaque** étage, de la préparation jusqu'à l'arbitrage. Comparer deux étages successifs montre ce que l'étage a apporté : un étage qui fait monter le rappel, un étage qui fait baisser les hallucinations, ou un étage qui dégrade le résultat et doit être revu. C'est ainsi que certaines règles ont été gardées et d'autres abandonnées.

La stabilité. Les mêmes mesures sont faites séparément sur deux moitiés du corpus. Un gain qui n'apparaît que sur une moitié est probablement dû au hasard ; un vrai gain apparaît sur les deux.

La structure du graphe, sans gold. L'étage compte aussi, sans regarder le gold : les relations orphelines (qui pointent vers une entité absente), les relations non conformes au guideline, les relations en double, et les éléments dont un terme n'est pas dans le texte. Ces mesures vérifient que le graphe est propre, indépendamment de sa justesse.

Entraîner le vote du mode précision

Le vote de l'étage 7 a besoin d'exemples dont on connaît la réponse. Comme seul l'étage 8 lit le gold, c'est lui qui les fournit.

1. **Collecter les exemples.** On prend le graphe tel qu'il sort de l'étage 6, juste avant la décision. Pour chaque relation et chaque entité, on calcule les mêmes indices que l'étage 7 utilisera.
2. **Les étiqueter.** Le rapprochement avec le gold dit si chaque élément est juste ou faux.
3. **Choisir les bons exemples.** Pour les entités, on ne garde que celles que les règles E1, E2 et E3 laissent passer : le vote n'aura à trier que celles-là, il doit donc apprendre sur elles.
4. **Apprendre les poids.** Deux modèles sont appris : un pour les entités, un pour les relations.
5. **Calculer les seuils.** Pour plusieurs parts à garder (presque tout, la grande majorité, les quatre cinquièmes…), on calcule le score limite correspondant.

La validation croisée : mesurer le vote honnêtement

Le piège à éviter. Un modèle appris sur des documents les « connaît ». Si on le mesurait sur ces mêmes documents, il aurait l'air meilleur qu'il ne l'est réellement. C'est comme corriger un élève sur les exercices dont il a déjà vu le corrigé.

La méthode (Stone, 1974) :

1. Le corpus est coupé en deux moitiés.
2. Le vote apprend sur la première moitié seulement.
3. L'étage 7 **complet** (règles, cascade, vote) est appliqué à la seconde moitié, que le vote n'a jamais vue, et le résultat est mesuré.
4. On inverse : apprentissage sur la seconde moitié, mesure sur la première.
5. On additionne les deux mesures.
6. Tout cela est refait pour chaque part à garder.

Ainsi, **chaque document est jugé par un vote qui ne l'a jamais vu**. La mesure obtenue vaut pour des comptes rendus nouveaux. C'est elle qui sert à choisir la part à garder.

Le modèle livré. Une fois la mesure faite, le vote est réappris sur tout le corpus, pour profiter de tous les exemples. Ce modèle final est celui que l'étage 7 utilise.

Une mise en garde. Si l'on mesure le mode précision avec ce modèle final sur les mêmes documents, le résultat est trop optimiste, puisque le modèle les a vus. L'étage 8 le signale lui-même ; seule la mesure par validation croisée doit être retenue.

La règle du seuil d'ajout

Cette règle explique pourquoi certains ajouts sont gardés et d'autres non, à la seconde passe comme à la récupération structurée.

L'idée. Ajouter un élément a deux effets contraires. S'il est juste, on trouve une chose de plus : le rappel monte. S'il est faux, on affirme une erreur de plus : la précision baisse. Un ajout n'améliore donc le résultat global que s'il est juste **assez souvent**.

Où se trouve ce « assez souvent ». Il se déduit de la définition du F1. Un ajout fait monter le F1 seulement s'il est juste plus souvent que **la moitié de la qualité actuelle** du graphe. Plus le graphe est déjà bon, plus les ajouts doivent être fiables pour l'améliorer encore. Pour les graphes de TRACE, cela revient à environ un ajout juste sur trois.

Comment la règle est appliquée sans tricher.

1. On regarde, sur une moitié du corpus, quels groupes d'ajouts (par type, par vote, par proximité des termes…) dépassent ce seuil.
2. On garde ces groupes, puis on mesure l'effet sur l'autre moitié.
3. On inverse les moitiés.

4. Un groupe n'est retenu que s'il améliore le résultat **sur les deux moitiés**.

Ce que la règle a donné.

- Seconde passe, entités : certains types dépassent le seuil des deux côtés et sont gardés.
- Seconde passe, relations : aucun groupe ne dépasse le seuil des deux côtés. Le seul filtre qui retenait quelque chose sur une moitié dégradait le résultat sur l'autre. Les relations ajoutées sont donc toutes écartées.
- Récupération structurée : relier un traitement à sa posologie sur la même ligne améliore le résultat des deux côtés et est gardé ; relier chaque traitement au patient le dégrade et a été abandonné.

Les autres seuils. Les seuils qui ne sont pas appris (ce qu'est une ligne, un paragraphe, la fenêtre avant une négation, la part de mots requise pour reconnaître un terme) sont fixés à l'avance d'après la forme des comptes rendus, et jamais ajustés en regardant le gold.

Ce que TRACE garantit, et ses limites

Ce que TRACE garantit.

- Tout élément gardé est retrouvé dans le texte du compte rendu ; tout ajout de TRACE est une copie du texte.
- Toute relation gardée est jugée par rapport aux signatures du guideline, et son écart éventuel est signalé.
- Un fait nié n'est jamais présenté comme affirmé.
- Chaque retrait a une règle nommée pour cause ; chaque élément gardé a un niveau de confiance expliqué.
- Aucune règle n'est réglée en regardant les réponses : ce qui est appris est mesuré sur des documents jamais vus.

Ses limites.

- **Le rappel dépend de l'extraction.** TRACE retire, répare et complète les parties à forme fixe, mais il ne peut pas retrouver une information du texte libre que le modèle n'a jamais vue. Pour aller plus loin, il faut agir à l'extraction.
- **Le mode précision coûte du rappel.** Retirer plus d'éléments douteux retire aussi des éléments justes. Le choix de la part gardée dépend de l'usage.
- **Un seul corpus.** Les règles sont validées sur deux moitiés indépendantes, mais pas encore sur les comptes rendus d'un autre centre.
- **Le niveau de confiance n'est pas une probabilité.** C'est un compte de raisons de douter.

- **Le guideline évolue.** La conformité au guideline et la réparation doivent toujours utiliser la même version que l'extraction et l'annotation ; elles doivent être mises à jour vers la version 2.0.
- **« Faux » veut dire « absent de l'annotation de référence ».** Quelques éléments comptés comme faux sont peut-être justes mais non annotés.

Références

Référence	Utilisée pour
Ji, Z. et al. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12).	Définir l'hallucination
Huang, L. et al. (2025). A Survey on Hallucination in Large Language Models. *ACM Transactions on Information Systems*, 43(2).	Fidélité et factualité
Min, S. et al. (2023). FActScore. *EMNLP 2023*.	Vérifier chaque affirmation contre la source
Kadavath, S. et al. (2022). Language Models (Mostly) Know What They Know. *arXiv:2207.05221*.	Confiance déclarée par le modèle
Wang, X. et al. (2023). Self-Consistency. *ICLR 2023*.	Accord entre plusieurs réponses
Manakul, P., Liusie, A. & Gales, M. (2023). SelfCheckGPT. *EMNLP 2023*.	Accord entre plusieurs réponses
Kamoi, R. et al. (2024). When Can LLMs Actually Correct Their Own Mistakes? *TACL*, 12.	Limites de l'auto-correction
Huang, J. et al. (2024). Large Language Models Cannot Self-Correct Reasoning Yet. *ICLR 2024*.	Limites de l'auto-correction
Kim, G. et al. (2022). OCR-free Document Understanding Transformer (Donut). *ECCV 2022*.	Lecture directe de l'image
Xu, Y. et al. (2020). LayoutLM. *KDD 2020*.	Lecture directe de l'image
Knublauch, H. & Kontokostas, D. (2017). Shapes Constraint Language (SHACL). *W3C Recommendation*.	Contraintes de forme

Référence	Utilisée pour
Ali, M., Taha, Z. & Morsey, M. M. (2026). Ontology-grounded knowledge graphs for mitigating hallucinations in LLMs for clinical question answering. *Journal of Biomedical Informatics*, 175.	Référentiel clinique contre les hallucinations
Paulheim, H. (2017). Knowledge Graph Refinement. *Semantic Web*, 8(3).	Raffinement des graphes
Chu, X., Ilyas, I. F. & Papotti, P. (2013). Holistic Data Cleaning. *ICDE 2013*.	Réparation sous contraintes
Rekatsinas, T. et al. (2017). HoloClean. *PVLDB*, 10(11).	Réparation sous contraintes
Fan, W., Wu, Y. & Xu, J. (2016). Functional Dependencies for Graphs. *SIGMOD 2016*.	Réparation sous contraintes
Gangemi, A. (2005). Ontology Design Patterns for Semantic Web Content. *ISWC 2005*.	Patrons de modélisation
Noy, N. & Rector, A. (2006). Defining N-ary Relations on the Semantic Web. *W3C Working Group Note*.	Lien représenté par un nœud
Chow, C. K. (1970). On Optimum Recognition Error and Reject Tradeoff. *IEEE Transactions on Information Theory*, 16(1).	Abstention
Geifman, Y. & El-Yaniv, R. (2017). Selective Classification for Deep Neural Networks. *NeurIPS 2017*.	Abstention
Du, Y. et al. (2024). Improving Factuality and Reasoning through Multiagent Debate. *ICML 2024*.	Débat entre modèles (contraste)
Savova, G. K. et al. (2010). cTAKES. *JAMIA*, 17(5).	Extraction clinique par règles
Fraile Navarro, D. et al. (2023). Clinical NER and relation extraction: a systematic review. *International Journal of Medical Informatics*, 177.	Extraction clinique par règles
Chapman, W. W. et al. (2001). NegEx. *Journal of Biomedical Informatics*, 34(5).	Négation
Harkema, H. et al. (2009). ConText. *Journal of Biomedical Informatics*, 42(5).	Hypothèse et temporalité

Référence	Utilisée pour
Ratner, A. et al. (2017). Snorkel. *PVLDB*, 11(3).	Combiner des signaux faibles
Cox, D. R. (1958). The Regression Analysis of Binary Sequences. *Journal of the Royal Statistical Society B*, 20(2).	Régression logistique
Stone, M. (1974). Cross-Validatory Choice and Assessment of Statistical Predictions. *Journal of the Royal Statistical Society B*, 36(2).	Validation croisée